

On s'intéresse à l'efficacité du vaccin contre la rougeole à partir de données épidémiques au Burundi (voir [1]). Trois classes d'âges sont considérées (première colonne du tableau 1) et on désigne par  $x_i$  le nombre de cas correspondant à la classe d'âge  $i$  parmi les  $N_{1i}$  enfants vaccinés et  $y_i$  le nombre de cas parmi les  $N_{0i}$  non vaccinés.

Classe d'âge (mois)	vaccinés		non vaccinés	
	$x$	$N_1$	$y$	$N_0$
Première classe : $[9 - 15]$	16	90	62	109
Deuxième classe : $[16 - 36]$	60	449	34	84
Troisième classe : $[37 - 60]$	33	413	3	19
Total	109	952	99	212

TABLE 1

La mesure standard de l'efficacité d'un vaccin s'obtient de la manière suivante : dans le cadre d'un modèle en *tout et rien* (appelé communément modèle II), il s'agit de la fraction  $\pi$  d'individus qui s'ils sont vaccinés, passent de *susceptible d'être infecté* à *complètement immunisé*. La fraction complémentaire  $1 - \pi$  a le même risque d'infection que la population non vaccinée. On désigne par  $p_1$  la probabilité d'infection chez les vaccinés et  $p_0$  la probabilité d'infection chez les non vaccinés (au cours d'une période donnée). Pour une classe d'âge  $i$ , on considérera donc  $p_{0i}, p_{1i}$  et  $\pi_i$ .

## 1. PRÉLIMINAIRES

- (1) En supposant qu'il y a indépendance d'un individu à l'autre, quelle est la loi de probabilité du nombre de cas infectés chez les vaccinés et chez les non vaccinés dans une classe d'âge (c'est cette loi de probabilité qui sera utilisée dans la suite du devoir) ? Cette hypothèse vous semble-t-elle raisonnable pour les maladies infectieuses ?
- (2) Écrire  $p_{1i}$  en fonction de  $p_{0i}$  et  $\pi_i$  et en déduire l'efficacité  $\pi_i$  en fonction de  $p_{0i}$  et  $p_{1i}$ . On notera cette fonction  $h : \pi_i = h(p_{0i}, p_{1i})$ .

## 2. HOMOGENÉITÉ PAR RAPPORT À L'ÂGE

On suppose que les probabilités d'infection  $p_{0i}$  et  $p_{1i}$  sont identiques et respectivement égales à  $p_0$  et  $p_1$  pour les trois classes d'âges.

- (1) Écrire la vraisemblance  $\ell(p_0, \pi)$  et la log-vraisemblance (on notera  $x = x_1 + x_2 + x_3, y = y_1 + y_2 + y_3, N_1 = N_{11} + N_{12} + N_{13}, N_0 = N_{01} + N_{02} + N_{03}$ ).
- (2) Dans un premier temps, on suppose que  $p_0$  est une constante connue.
  - (a) Calculer l'estimateur du maximum de vraisemblance  $\hat{\pi}_E$  de  $\pi$  en fonction de  $p_0$ .
  - (b) Quelles sont l'espérance et la variance de l'estimateur  $\hat{\pi}_E$  en fonction de  $p_1$  et  $p_0$  puis de  $\pi$  et  $p_0$  ?
  - (c) Calculer l'information de Fisher  $I(\pi)$  (en fonction de  $\pi$  et  $p_0$ ). L'estimateur  $\hat{\pi}_E$  est-il de variance minimale ?
  - (d) Quelle est la loi asymptotique de  $\hat{\pi}_E$  ?
  - (e) On suppose que  $p_0 = 50\%$ . On se demande si ce vaccin a une efficacité supérieure à 60%.
    - Écrire les hypothèses nulle et alternative correspondantes.
    - Proposer un test basé sur la loi asymptotique de  $\hat{\pi}_E$ .

- Effectuer le test de (en supposant les approximations asymptotiques légitimes) au risque 5%. Que concluez-vous ?
  - Écrire la puissance de ce test pour  $\pi = 75\%$  (On utilisera le résultat de la question (d)). Est-elle supérieure à 90% ?
- (3) On suppose désormais que  $p_0$  n'est pas connu. On veut calculer l'estimateur du maximum de vraisemblance  $\hat{\pi}_{MV}$  de  $\pi$ . Cela sort du cadre du cours puisqu'il y a deux paramètres inconnus. Il s'agit donc de résoudre un système de deux équations (égalité à zéro des dérivées partielles par rapport à  $\pi$  et  $p_0$ ) à deux inconnues. Procéder de la manière suivante :
- (a) Écrire la dérivée de la log-vraisemblance obtenue à la question (1) par rapport à  $p_0$  comme si  $\pi$  était une constante connue (il s'agit donc d'une dérivée partielle).
  - (b) Remplacer ensuite  $\pi$  par l'estimateur de maximum de vraisemblance  $\hat{\pi}_E$  fonction de  $p_0$ , obtenu à la question (2) (a).
  - (c) En déduire l'estimateur du maximum de vraisemblance  $\hat{p}_{0MV}$  de  $p_0$ .
  - (d) En déduire l'estimateur du maximum de vraisemblance  $\hat{\pi}_{MV}$  de  $\pi$ . On remarque que  $\hat{\pi}_{MV}$  s'écrit en fonction de  $\hat{p}_{0MV}$  et de  $\hat{p}_{1MV} = \frac{x}{N_1}$ . Quelle est sa valeur numérique ? Quelle est la valeur numérique du logarithme népérien de la vraisemblance maximale (aux constantes additives près) ?

### 3. HÉTÉROGÉNÉITÉ PAR RAPPORT À L'ÂGE

On considère que les probabilités d'infection peuvent être différentes suivant les classes d'âge, avec des efficacités spécifiques à chaque classe d'âge.

- (1) Écrire la vraisemblance  $L_i(p_{0i}, \pi_i)$  correspondant à la classe d'âge  $i$ .
  - (2) Écrire la log-vraisemblance  $L_i(p_{0i}, \pi_i)$  et calculer l'estimateur du maximum de vraisemblance  $\hat{\pi}_{iMV}$  de  $\pi_i$ .
  - (3) On se demande si on est dans la situation 2 (homogénéité par rapport à l'âge) ou 3 (hétérogénéité).
  - (4) Écrire les hypothèses nulle et alternative correspondantes.
  - (5) On souhaite tester ces hypothèses avec un test dit *de rapport de vraisemblances* (en supposant que l'on puisse utiliser les résultats asymptotiques) que nous allons construire ici.
- (a) Écrire la vraisemblance  $L(\pi_1, p_{01}, \pi_2, p_{02}, \pi_3, p_{03})$  sous  $H_1$ .
  - (b) Écrire le rapport des vraisemblances sous  $H_1$  et  $H_0$ <sup>1</sup> :

$$\frac{L(\pi_1, p_{01}, \pi_2, p_{02}, \pi_3, p_{03})}{L(p_0, \pi)}.$$

- (c) En remplaçant  $p_{0i}$  et  $\pi_i$  par  $\hat{p}_{0iMV}$  et  $\hat{\pi}_{iMV}$ , on trouve que le logarithme népérien de la vraisemblance maximale sous  $H_1$ , aux mêmes constantes additives près qu'à la question 3)(d) de la partie 2, vaut  $-473.21$ . Calculer la valeur numérique de la statistique du rapport de vraisemblances  $S$  donnée par

$$S = 2 \ln \left[ \frac{L(\pi_1, p_{01}, \pi_2, p_{02}, \pi_3, p_{03})}{L(p_0, \pi)} \right],$$

en remplaçant chaque paramètre par la valeur de son estimateur par maximum de vraisemblance.<sup>2</sup>

1. Indication : La vraisemblance sous  $H_0$  est calculée à la question 1) dans la partie 2.

2. penser à ce vous avez obtenu à la question 3)(d) de la partie 2

Nous avons ici 6 paramètres pour  $H_1$  et 2 paramètres pour  $H_0$  (qui est emboîté dans  $H_1$ ). La statistique de test  $S$  est distribuée sous  $H_0$  suivant une loi du  $\chi^2$  dont le nombre de degrés de liberté est la différence  $6 - 2 = 4$ . Conclure au risque 5%<sup>3</sup>.

#### RÉFÉRENCES

- [1] C. M. Hernández-Suárez and C. Castillo-Chavez. Urn models and vaccine efficacy estimation. *Statistics in Medicine*, 19(6) :827–835, 2000.

---

3. Faire appel à un logiciel (R par exemple) pour calculer le quantile correspondant.