Démarche statistique **(à rendre au plus tard le dimanche 11/01/2026)**

Devoir

Enseignant: Mohammed Sedki *pageweb:* masedki.github.io

Instructions :
Le devoir est à rendre sous format d'un fichier pdf (scans de vos notes par smartphone à l'aide d'adobe scan par exemple) nommé `prenom_nom.pdf` ou `prenom1_nom1_prenom2_nom2.pdf` pour un binôme.

Problème : intervalle de confiance d'un coefficient de corrélation (8 points)

Pour $i = 1, 2, \dots n$, les variables aléatoires X_i et Y_i désignent, respectivement, la pression sanguine diastolique et la pression sanguine systolique pour le ième de n hommes adultes hypertendus choisis au hasard. Supposons que les paires $(X_i, Y_i), \quad i = 1, 2, \dots, n$, constituent un échantillon aléatoire de taille n provenant d'une loi normale à deux variables, où $\mathbb{E}(X_i) = \mu_x$, $\mathbb{E}(Y_i) = \mu_y$, $\mathrm{Var}(X_i) = \mathrm{Var}(Y_i) = \sigma^2$ et $\mathrm{corr}(X_i, Y_i) = \rho$. L'objectif est de développer un intervalle de confiance (IC) à 95% exact pour le coefficient de corrélation ρ. Pour atteindre cet objectif, on considère les variables aléatoires $U_i = (X_i + Y_i)$ et $V_i = (X_i - Y_i)$, $i = 1, 2, \dots, n$. De plus, on définit $n\bar{U}_n = \sum_{i=1}^n U_i$, $n\bar{V}_n = \sum_{i=1}^n V_i$, $(n-1)S_u^2 = \sum_{i=1}^n \left(U_i - \bar{U}_n\right)^2$ et $(n-1)S_v^2 = \sum_{i=1}^n \left(V_i - \bar{V}_n\right)^2$.

1. Calculer $\mathbb{E}(U_i)$, $\mathrm{Var}(U_i)$, $\mathbb{E}(V_i)$ et $\mathrm{Var}(V_i)$.

2. Vérifier que $\mathrm{Cov}(U_i, V_i) = 0$ pour tout $i = 1, 2, \dots, n$. Dans cette situation, on en déduit que U_i et V_i sont des variables aléatoires indépendantes, $i = 1, 2, \dots, n$.

3. Utiliser des arguments rigoureux pour montrer que la variable aléatoire

$$W = \frac{(1-\rho)S_u^2}{(1+\rho)S_v^2}$$

suit une loi de Fisher. [1] Préciser ses deux degrés de liberté. [2]

4. Si $n = 10$, et si les valeurs observées de S_u^2 et S_v^2 sont 1.0 et 2.0, respectivement, utiliser ces données pour proposer un intervalle de confiance à 95% de ρ.

Problème : seconde partie et fin (12 points)

Considérons un modèle exponentiel pour le temps de survie dans un essai randomisé et contrôlé par placebo de l'azathioprine pour la cirrhose biliaire primitive. Les temps de survie (en jours) des n patients du groupe placebo sont donnés par les variables aléatoires X_i avec les indicatrices d'absence de censure $\gamma_i \quad i = 1, \dots, n$, tandis que les temps de survie des m patients du groupe de contrôle sont désignés par Y_i et ont des indicatrices d'absence de censure $\delta_i \quad i = 1, \dots, m$. Les temps de survie non censurés suivent des modèles exponentiels avec les paramètres η et $\eta\theta$ dans les groupes placebo et traités respectivement $(\eta, \theta > 0)$.

1. Interpréter les paramètres η et θ.
2. Écrire la vraisemblance comme le produit des vraisemblances associées aux groupes placebo et contrôle respectivement [3].
3. Montrer que la log-vraisemblance des données est donnée par

$$\ell\big(\eta, \theta\big) = (n\bar{\gamma} + m\bar{\delta})\log(\eta) + m\bar{\delta}\log(\theta) - \eta(n\bar{x} + m\theta\bar{y}),$$

où $\bar{\gamma}, \bar{\delta}, \bar{x}$ et $\bar{y}$ sont les moyennes empiriques des γ_i, δ_i, x_i et y_i respectivement.

1. Indication : si $X_1, \dots, X_n$ sont iid de loi $\mathcal{N}(0,1)$ alors $\sum_{i=1}^n \left(X_i - \bar{X}_n\right)^2$,suit une loi du khi-deux à $n-1$ degré de liberté.
2. Indication : rappeler la définition d'une v.a de loi de Fisher à partir de deux v.a de lois du khi-deux indépendantes.
3. **Indication :** La vraisemblance d'un individu correspond à la densité d'une exponentielle évaluée au temps de survie de l'individu s'il n'est pas censuré et à la fonction de survie évaluée au temps de survie de l'individu si ce dernier est censuré.

4. Calculer le MLE $\big(\hat{\eta}_{\mathrm{ML}}, \hat{\theta}_{\mathrm{ML}}\big)$.
5. Proposer une approximation de la matrice d'information de Fisher $I_{m,n}\big(\hat{\eta}_{\mathrm{ML}}, \hat{\theta}_{\mathrm{ML}}\big)$ apportée par toutes les observations en remplaçant $\mathbb{E}\big(\gamma_i\big)$ et $\mathbb{E}\big(\delta_i\big)$ par les estimateurs appropriés [4]. Dans le cas d'un vecteur de paramètres, l'information de Fisher est une matrice symétrique où $-\mathbb{E}\left(\frac{\partial^2}{\partial\eta^2}\ell\big(\eta,\theta\big)\right)$ et $-\mathbb{E}\left(\frac{\partial^2}{\partial\theta^2}\ell\big(\eta,\theta\big)\right)$ sont les éléments diagonaux et $-\mathbb{E}\left(\frac{\partial^2}{\partial\theta\partial\eta}\ell\big(\eta,\theta\big)\right)$ est l'élément anti-diagonal.
6. Dans le cas d'un paramètre multidimensionnel, la loi asymptotique du paramètre $\widehat{\theta}_{\mathrm{ML}}$ est donnée par

$$\widehat{\theta}_{\mathrm{ML}} \sim \mathcal{N}\Big(\theta, I_{m,n}\big(\hat{\eta}_{\mathrm{ML}}, \hat{\theta}_{\mathrm{ML}}\big)^{-1}_{22}\Big),$$

où $I_{m,n}\big(\hat{\eta}_{\mathrm{ML}}, \hat{\theta}_{\mathrm{ML}}\big)^{-1}_{22}$ correspond à l'élément 22 de l'inverse de la matrice d'information de Fisher obtenue en remplaçant η et θ par les estimateurs $\hat{\eta}_{\mathrm{ML}}$ et $\hat{\theta}_{\mathrm{ML}}$.

— (**Difficile**) Déduire que $\hat{\theta}_{\mathrm{ML}}\sqrt{\frac{n\bar{\gamma}+m\bar{\delta}}{n\bar{\gamma}m\bar{\delta}}}$ est une approximation de l'écart type asymptotique de $\hat{\theta}_{\mathrm{ML}}$ et proposer une formule générale d'un intervalle de confiance $\alpha\cdot 100\%$ asymptotique.

La δ-méthode

Un théorème appelé δ-méthode permet de déduire la normalité asymptotique d'une transformation d'un estimateur. Soit $\widehat{\theta}_n$ un estimateur asymptotiquement normal autour de θ et de variance asymptotique σ^2 comme suit

$$\sqrt{n}\Big(\widehat{\theta}_n - \theta\Big) \to \mathcal{N}(0,\sigma^2) \quad \text{en loi quand} \quad n\to\infty.$$

Pour toute fonction g dérivable telle que $g'(\theta)\neq 0$, nous avons la normalité asymptotique suivante

$$\sqrt{n}\Big(g\big(\widehat{\theta}_n\big) - g\big(\theta\big)\Big) \to \mathcal{N}\Big(0, \sigma^2[g'(\theta)]^2\Big) \quad \text{en loi quand} \quad n\to\infty.$$

7. Considérer la transformation $\psi = \log(\theta)$. À l'aide de la δ-méthode, proposer un intervalle de confiance $\alpha\cdot 100\%$ asymptotique pour ψ.

4. On considère que la moyenne empirique est une bonne approximation de la moyenne théorique pour les X_i et Y_i. Dans cette question nous n'avons pas besoin de faire un calcul d'espérence.