

Estimation ponctuelle

Statistique mathématique
M2 santé publique, université Paris-Sud

16 octobre 2018

1. Notion de statistique
2. Statistique libre
3. Exhaustivité
 - ▶ Exhaustivité
 - ▶ Caractérisation de l'exhaustivité
4. Exhaustivité minimale
 - ▶ Caractérisation de l'exhaustivité minimale
5. Complétude
 - ▶ Relation entre *libre* et *exhaustive*
 - ▶ Relation entre *Complète* et *exhaustive minimale*

Modèle statistique et problème d'inférence

Rappelons que nous avons

- ▶ Collection de v.a (un vecteur aléatoire) $X = (X_1, \dots, X_n)$
- ▶ $X \sim F_\theta \in \mathcal{F}$, souvent on fera appel à $f(x; \theta)$ au lieu de F_θ .
- ▶ \mathcal{F} une famille paramétrique $\theta \in \Theta \subseteq \mathbb{R}^d$

Modèle statistique et problème d'inférence

Rappelons que nous avons

- ▶ Collection de v.a (un vecteur aléatoire) $X = (X_1, \dots, X_n)$
- ▶ $X \sim F_\theta \in \mathcal{F}$, souvent on fera appel à $f(x; \theta)$ au lieu de F_θ .
- ▶ \mathcal{F} une famille paramétrique $\theta \in \Theta \subseteq \mathbb{R}^d$

Le problème de l'estimation ponctuelle

- ▶ Supposons que F est complètement définie par son paramètre θ
inconnu
- ▶ Soit (x_1, \dots, x_n) des réalisations de $X \sim F_\theta$
- ▶ Estimer la valeur de θ qui a **généré** les réalisations (x_1, \dots, x_n)

Modèle statistique et problème d'inférence

Rappelons que nous avons

- ▶ Collection de v.a (un vecteur aléatoire) $X = (X_1, \dots, X_n)$
- ▶ $X \sim F_\theta \in \mathcal{F}$, souvent on fera appel à $f(x; \theta)$ au lieu de F_θ .
- ▶ \mathcal{F} une famille paramétrique $\theta \in \Theta \subseteq \mathbb{R}^d$

Le problème de l'estimation ponctuelle

- ▶ Supposons que F est complètement définie par son paramètre θ **inconnu**
- ▶ Soit (x_1, \dots, x_n) des réalisations de $X \sim F_\theta$
- ▶ Estimer la valeur de θ qui a **généré** les réalisations (x_1, \dots, x_n)

L'information qu'on possède : c'est (x_1, \dots, x_n) et \mathcal{F}

- ▶ Ce qu'on peut construire n'est rien d'autre qu'une **fonction** des données $g(x_1, \dots, x_n)$
- ▶ Nous allons étudier les propriétés de telles fonctions et la perte d'information qu'on subit (une fonction de (x_1, \dots, x_n) apporte au plus la même information que l'échantillon entier. Souvent on subit une perte d'information)

Notion de statistique

Définition d'une statistique

Soit X un échantillon (des v.a iid) issu de F_θ . une **statistique** est une fonction (ou application) **mesurable** T qui envoie X dans \mathbb{R}^d et ne dépend pas de θ .

- ▶ Intuitivement, toute fonction de l'échantillon est une statistique.
- ▶ Toute statistique est elle même une v.a avec sa propre loi.

Notion de statistique

Définition d'une statistique

Soit X un échantillon (des v.a iid) issu de F_θ . une **statistique** est une fonction (ou application) **mesurable** T qui envoie X dans \mathbb{R}^d et ne dépend pas de θ .

- ▶ Intuitivement, toute fonction de l'échantillon est une statistique.
- ▶ Toute statistique est elle même une v.a avec sa propre loi.

Exemple

- ▶ $T(X) = n^{-1} \sum_{i=1}^n X_i$ est une statistique (rappelons que la taille de l'échantillon n est connue).
- ▶ $T(X) = (X_{(1)}, \dots, X_{(n)})$ où $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ sont les statistiques d'ordre de X . Puisque T dépend seulement des valeurs de X , T est une statistique.
- ▶ Soit $T(X) = c$, où c est une constante. Alors T est une statistique.

Statistique et information sur θ

- ▶ Parmi les exemples précédents, certaines statistiques sont plus informatives que d'autres au vu de la vraie valeur de θ .
- ▶ Une question naturelle : Quelles sont les *bonnes* statistiques et les *mauvaises* statistiques.

Statistique libre

Une statistique T est dite **libre** (pour θ) si sa loi de probabilité ne dépend pas *fonctionnellement* de θ .

\rightsquigarrow Donc une statistique libre a la même loi $\forall \theta \in \Theta$.

Statistique et information sur θ

- ▶ Parmi les exemples précédents, certaines statistiques sont plus informatives que d'autres au vu de la vraie valeur de θ .
- ▶ Une question naturelle : Quelles sont les *bonnes* statistiques et les *mauvaises* statistiques.

Statistique libre

Une statistique T est dite **libre** (pour θ) si sa loi de probabilité ne dépend pas *fonctionnellement* de θ .

\rightsquigarrow Donc une statistique libre a la même loi $\forall \theta \in \Theta$.

Exemple

Supposons que $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2)$ (où μ est inconnu et σ^2 est connu). Soit $T(X_1, \dots, X_n) = X_1 - X_2$.

Statistique et information sur θ

- ▶ Parmi les exemples précédents, certaines statistiques sont plus informatives que d'autres au vu de la vraie valeur de θ .
- ▶ Une question naturelle : Quelles sont les *bonnes* statistiques et les *mauvaises* statistiques.

Statistique libre

Une statistique T est dite **libre** (pour θ) si sa loi de probabilité ne dépend pas *fonctionnellement* de θ .

\rightsquigarrow Donc une statistique libre a la même loi $\forall \theta \in \Theta$.

Exemple

Supposons que $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2)$ (où μ est inconnu et σ^2 est connu). Soit $T(X_1, \dots, X_n) = X_1 - X_2$. La loi de T est normale de moyenne 0 et de variance $2\sigma^2$. On déduit que T est une statistique libre pour le paramètre inconnu μ . Si μ et σ^2 sont inconnus, T n'est pas libre pour le paramètre vectoriel $\theta = (\mu, \sigma^2)$.

Statistique et information sur θ

- ▶ Si T est libre pour θ alors T ne contient pas d'information sur θ .
- ▶ Pour contenir une information utile sur θ , la loi de T doit dépendre explicitement de θ .
- ▶ Intuitivement, la *quantité* d'information apportée par T sur θ est proportionnelle à la **dépendance** de la loi de T de θ .

Statistique et information sur θ

- ▶ Si T est libre pour θ alors T ne contient pas d'information sur θ .
- ▶ Pour contenir une information utile sur θ , la loi de T doit dépendre explicitement de θ .
- ▶ Intuitivement, la *quantité* d'information apportée par T sur θ est proportionnelle à la **dépendance** de la loi de T de θ .

Exemple

Soit $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \mathcal{U}[0, \theta]$, $S = \min(X_1, \dots, X_n)$ et $T = \max(X_1, \dots, X_n)$.

- ▶ $f_S(x, \theta) = \frac{n}{\theta} \left(1 - \frac{x}{\theta}\right)^{n-1}$, où $0 \leq x \leq \theta$
- ▶ $f_T(x, \theta) = \frac{n}{\theta} \left(\frac{x}{\theta}\right)^{n-1}$, où $0 \leq x \leq \theta$
 - ▶ Aucune des deux statistiques S et T n'est libre pour θ .
 - ▶ Quand $n \rightarrow +\infty$ f_S se concentre autour de 0.
 - ▶ Quand $n \rightarrow +\infty$ f_T se concentre autour de θ .
- ▶ On déduit que T apporte plus d'information sur θ que S .

Statistique et information sur θ

- ▶ $X = (X_1, \dots, X_n) \stackrel{\text{iid}}{\sim} F_\theta$ et $T(X)$ une statistique.
- ▶ On définit les ensembles de niveaux de T

$$A_t = \{x \in \mathbb{R}^n : T(x) = t\}.$$

(Ensemble des échantillons qui mènent à la même valeur t de T).

- ▶ T est constante quand on se restreint à A_t .
- ▶ Toutes les réalisations de X qui appartiennent au même ensemble de niveau sont équivalentes vis à vis de T .
- ▶ Toutes les inférences sont les mêmes à l'intérieur du même ensemble de niveau A_t .
- ▶ Regardons la loi de X dans l'ensemble de niveau A_t c'est à dire $f_{X|T=t}$

Statistique et information sur θ

- (1) Si $f_{X|T=t}$ dépend de θ alors : **perte d'information**.
- (2) Si l'expression de $f_{X|T=t}$ ne dépend pas de θ
 - ▶ X ne contient pas d'information sur θ dans l'ensemble A_t .
 - ▶ Autrement dit : X est libre pour θ dans A_t .

Statistique et information sur θ

- (1) Si $f_{X|T=t}$ dépend de θ alors : **perte d'information**.
- (2) Si l'expression de $f_{X|T=t}$ ne dépend pas de θ
 - ▶ X ne contient pas d'information sur θ dans l'ensemble A_t .
 - ▶ Autrement dit : X est libre pour θ dans A_t .

Interprétation de la deuxième situation

Si cela est vrai pour tout $t \in \text{Image}(T)$ alors $T(X)$ contient la même quantité d'information sur θ que ce que peut contenir X .

- ▶ Il n'y a pas de différence entre l'observation de $X = (X_1, \dots, X_n)$ entier et $T(X)$.
- ▶ La connaissance de la valeur de X en plus de $T(X)$ n'apporte aucune information supplémentaire sur X .

Statistique et information sur θ

- (1) Si $f_{X|T=t}$ dépend de θ alors : **perte d'information**.
- (2) Si l'expression de $f_{X|T=t}$ ne dépend pas de θ
 - ▶ X ne contient pas d'information sur θ dans l'ensemble A_t .
 - ▶ Autrement dit : X est libre pour θ dans A_t .

Interprétation de la deuxième situation

Si cela est vrai pour tout $t \in \text{Image}(T)$ alors $T(X)$ contient la même quantité d'information sur θ que ce que peut contenir X .

- ▶ Il n'y pas de différence entre l'observation de $X = (X_1, \dots, X_n)$ entier et $T(X)$.
- ▶ La connaissance de la valeur de X en plus de $T(X)$ n'apporte aucune information supplémentaire sur X .

Statistique exhaustive

Une statistique $T = T(X)$ est dite **exhaustive** pour le paramètre θ si pour tout ensemble (**Borelien**) B , la probabilité $\mathbb{P}[X \in B \mid T(X) = t]$ ne dépend pas de θ .

Statistique exhaustive

Exemple

Soit $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bernoulli}(\theta)$ et $T(X) = \sum_{i=1}^n X_i$. Soit $x \in \{0, 1\}^n$,

$$\begin{aligned}\mathbb{P}[X = x \mid T = t] &= \frac{\mathbb{P}[X = x, T = t]}{\mathbb{P}[T = t]} \\ &= \frac{\mathbb{P}[X = x]}{\mathbb{P}[T = t]} \chi \left\{ \sum_{i=1}^n x_i = t \right\} \\ &= \frac{\theta^t (1 - \theta)^{n-t}}{C_n^t \theta^t (1 - \theta)^{n-t}} = \frac{1}{C_n^t}.\end{aligned}$$

- ▶ T est exhaustive pour θ .
- ▶ Les positions des 1 dans les n réalisations de Bernoulli importent peu : 0011101 vs 1000111 vs 1010101.

Statistique exhaustive

- ▶ La définition précédente est difficile à vérifier notamment dans le cas continu.
- ▶ Cette définition ne permet pas d'identifier facilement les statistiques exhaustives.

Statistique exhaustive

- ▶ La définition précédente est difficile à vérifier notamment dans le cas continu.
- ▶ Cette définition ne permet pas d'identifier facilement les statistiques exhaustives.

Théorème de factorisation de Fisher-Neyman

Supposons que l'échantillon $X = (X_1, \dots, X_n)$ a une densité jointe $f(x; \theta), \theta \in \Theta$. Une statistique $T = T(X)$ est exhaustive pour θ si et seulement si

$$f(x; \theta) = g(T(x), \theta)h(x).$$

Statistique exhaustive

Exemple : loi uniforme

Soit $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \mathcal{U}[0, \theta]$ où $f(x; \theta) = \frac{1}{\theta} \chi\{x \in [0, \theta]\}$. Montrons que $X_{(n)}$ est exhaustive pour θ .

Statistique exhaustive

Exemple : loi uniforme

Soit $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \mathcal{U}[0, \theta]$ où $f(x; \theta) = \frac{1}{\theta} \chi\{x \in [0, \theta]\}$. Montrons que $X_{(n)}$ est exhaustive pour θ .

$$\begin{aligned} f(x_1, \dots, x_n; \theta) &= \frac{1}{\theta^n} \chi\{x \in [0, \theta]^n\} \\ &= \frac{\chi\{\max [x_1, \dots, x_n] \leq \theta\} \chi\{\min [x_1, \dots, x_n] \geq 0\}}{\theta^n} \\ &= g\left(\max [x_1, \dots, x_n]; \theta\right) h(x_1, \dots, x_n) \end{aligned}$$

On déduit que la statistique $T(X) = X_{(n)} = \max [x_1, \dots, x_n]$ est exhaustive pour θ .

Statistique exhaustive

Exemple : famille exponentielle

Soit $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} f(x; \theta)$ où $f(x; \theta)$ est une densité associée à une loi issue de la famille exponentielle avec un certain nombre k de paramètres.

$$f(x; \theta) = \exp \left[\sum_{i=1}^k c_i(\theta) T_i(x) - d(\theta) + S(x) \right] \chi \{x \in A\}.$$

On choisit $h(x) = \exp [S(x)] \chi \{x \in A\}$, on déduit de théorème factorisation que la statistique

$$T = (T_1(X), \dots, T_k(X))$$

est exhaustive pour θ .

Statistique exhaustive

Preuve du théorème de Neyman-Fisher - cas discret

Supposons que T est exhaustive. Ainsi

Statistique exhaustive

Preuve du théorème de Neyman-Fisher - cas discret

Supposons que T est exhaustive. Ainsi

$$\begin{aligned} f(x; \theta) &= \mathbb{P}[X = x] = \sum_t \mathbb{P}[X = x, T = t] \\ &= \mathbb{P}[X = x, T = T(x)] = \mathbb{P}[T = T(x)] \mathbb{P}[X = x \mid T = T(x)]. \end{aligned}$$

Comme T est exhaustive, $\mathbb{P}[X = x \mid T = T(x)]$ est indépendante de θ et donc $f(x; \theta) = g(T(x); \theta)h(x)$.

Statistique exhaustive

Preuve du théorème de Neyman-Fisher - cas discret

Supposons que T est exhaustive. Ainsi

$$\begin{aligned} f(x; \theta) &= \mathbb{P}[X = x] = \sum_t \mathbb{P}[X = x, T = t] \\ &= \mathbb{P}[X = x, T = T(x)] = \mathbb{P}[T = T(x)] \mathbb{P}[X = x \mid T = T(x)]. \end{aligned}$$

Comme T est exhaustive, $\mathbb{P}[X = x \mid T = T(x)]$ est indépendante de θ et donc $f(x; \theta) = g(T(x); \theta)h(x)$.

Maintenant, supposons que $f(x; \theta) = g(T(x); \theta)h(x)$. Alors si $T(x) = t$,

$$\begin{aligned} \mathbb{P}[X = x \mid T = t] &= \frac{\mathbb{P}[X = x, T = t]}{\mathbb{P}[T = t]} = \frac{\mathbb{P}[X = x]}{\mathbb{P}[T = t]} \chi\{T(x) = t\} \\ &= \frac{g(T(x); \theta)h(x)\chi\{T(x) = t\}}{\sum_{y: T(y)=t} g(T(y); \theta)h(y)} = \frac{h(x)\chi\{T(x) = t\}}{\sum_{y: T(y)=t} h(y)}. \end{aligned}$$

Statistique exhaustive minimale

- ▶ Quand une statistique exhaustive apporte-t-elle de l'information importante seulement ?
- ▶ Peut-on renoncer à de l'information ? laquelle ? combien ?

Statistique exhaustive minimale

- ▶ Quand une statistique exhaustive apporte-t-elle de l'information importante seulement ?
- ▶ Peut-on renoncer à de l'information ? laquelle ? combien ?

Définition d'une statistique exhaustive minimale

Une statistique $T = T(X)$ est dite **exhaustive minimale** pour un paramètre θ si pour toute autre statistique S exhaustive pour θ , il existe une fonction $g(\cdot)$ où

$$T(X) = g(S(X)).$$

Statistique exhaustive minimale

- ▶ Quand une statistique exhaustive apporte-t-elle de l'information importante seulement ?
- ▶ Peut-on renoncer à de l'information ? laquelle ? combien ?

Définition d'une statistique exhaustive minimale

Une statistique $T = T(X)$ est dite **exhaustive minimale** pour un paramètre θ si pour toute autre statistique S exhaustive pour θ , il existe une fonction $g(\cdot)$ où

$$T(X) = g(S(X)).$$

Proposition

Si T et S sont des statistiques exhaustives minimales pour un paramètre θ , alors il existe des fonctions injectives g et h telles que $S = g(T)$ et $T = h(S)$.

Exhaustive minimale : caractérisation

Théorème

Soit $X = (X_1, \dots, X_n)$ un échantillon de densité jointe (ou fonction de masse) $f(x; \theta)$ et $T = T(X)$ une statistique. Si $\frac{f(x; \theta)}{f(y; \theta)}$ est indépendant de $\theta \Leftrightarrow T(x) = T(y)$, alors T est **exhaustive minimale** pour θ .

Exhaustive minimale : caractérisation

Théorème

Soit $X = (X_1, \dots, X_n)$ un échantillon de densité jointe (ou fonction de masse) $f(x; \theta)$ et $T = T(X)$ une statistique. Si $\frac{f(x; \theta)}{f(y; \theta)}$ est indépendant de $\theta \Leftrightarrow T(x) = T(y)$, alors T est **exhaustive minimale** pour θ .

Preuve (conditions \Rightarrow exhaustivité)

Soit $\mathcal{T} = \{T(y) : y \in \mathbb{R}^n\}$ l'image de \mathbb{R}^n par T et soit A_t un ensemble de niveau de T . Pour tout t , on choisit un représentant $y_t \in A_t$. Notons que pour tout x , $y_{T(x)}$ est dans le même ensemble de niveau que x , donc $f(x; \theta) / f(y_{T(x)}; \theta)$ ne dépend pas de θ par hypothèse. On pose $g(t, \theta) = f(y_t; \theta)$ et notons

$$f(x; \theta) = \frac{f(y_{T(x)}; \theta) f(y; \theta)}{f(y_{T(x)}; \theta)} = g(T(x); \theta) h(x),$$

on obtient ainsi l'exhaustivité par le théorème de factorisation.

Exhaustive minimale : caractérisation

Preuve (conditions \Rightarrow minimalité)

Soit T' une autre statistique exhaustive. Par le théorème de factorisation : $\exists g', h'$ telles que $f(x; \theta) = g'(T'(x); \theta)h'(x)$. Soit x et y tels que $T(x) = T(y)$. Alors

$$\frac{f(x; \theta)}{f(y; \theta)} = \frac{g'(T'(x); \theta)h'(x)}{g'(T'(y); \theta)h'(y)} = \frac{h'(x)}{h'(y)}.$$

Puisque ce rapport ne dépend pas de θ , nous avons par hypothèse $T(x) = T(y)$. Ainsi T est une fonction de T' ; donc elle est minimale par un choix arbitraire de T' .

Exhaustive minimale : exemple

Retour au modèle de Bernoulli

Soit $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bernoulli}(\theta)$. Soit x et $y \in \{0, 1\}^n$ deux réalisations possibles. Montrons que $T(x) = \sum_{i=1}^n x_i$ est exhaustive minimale.

Exhaustive minimale : exemple

Retour au modèle de Bernoulli

Soit $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bernoulli}(\theta)$. Soit x et $y \in \{0, 1\}^n$ deux réalisations possibles. Montrons que $T(x) = \sum_{i=1}^n x_i$ est exhaustive minimale. Nous avons

$$\frac{f(x; \theta)}{f(y; \theta)} = \frac{\theta^{\sum x_i} (1 - \theta)^{n - \sum x_i}}{\theta^{\sum y_i} (1 - \theta)^{n - \sum y_i}}$$

qui est constant si et seulement si $T(x) = \sum x_i = \sum y_i = T(y)$ et donc T est exhaustive minimale.

Statistique complète

- ▶ Statistique libre \rightarrow ne contient pas d'information sur θ
- ▶ Statistique exhaustive minimale \rightarrow contient toute l'information pertinente et un **peu** d'information non-pertinente.
- ▶ Ces deux aspects sont-ils indépendants ?

Statistique complète

- ▶ Statistique libre \rightarrow ne contient pas d'information sur θ
- ▶ Statistique exhaustive minimale \rightarrow contient toute l'information pertinente et un **peu** d'information non-pertinente.
- ▶ Ces deux aspects sont-ils indépendants ?

Définition d'une statistique complète

Soit $\{g(t; \theta) : \theta \in \Theta\}$ une famille de densités (ou fonctions de masse) pour $T(X)$. La statistique T est dite *complète* si pour toute fonction mesurable h , nous avons

$$\int h(t)g(t; \theta)dt = 0 \quad \forall \theta \in \Theta \implies \mathbb{P}[h(T) = 0] = 1 \quad \forall \theta \in \Theta$$

Statistique complète

Exemple

Soit $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bernoulli}(\theta)$, $\theta \in (0, 1)$, et $T = \sum_{i=1}^n X_i$. Vérifions que T est complète.

Statistique complète

Exemple

Soit $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bernoulli}(\theta)$, $\theta \in (0, 1)$, et $T = \sum_{i=1}^n X_i$. Vérifions que T est complète. Soit h une fonction arbitraire,

$$\mathbb{E}[h(T)] = \sum_{t=0}^n h(t) C_t^n \theta^t (1 - \theta)^{n-t} = (1 - \theta)^n \sum_{t=0}^n h(t) C_t^n \left(\frac{\theta}{1 - \theta} \right)^t$$

Puisque $\theta \in (0, 1)$, le rapport $\theta / (1 - \theta)$ varie dans $(0, \infty)$. Ainsi, supposons que $\mathbb{E}[h(T)] = 0$ pour tout $\theta \in (0, 1)$, nous avons

$$P(x) = \sum_{t=0}^n h(t) C_t^n x^t = 0 \quad x > 0,$$

i.e le polynôme $P(x)$ est uniformément nul sur l'ensemble des nombres réels positifs. Donc les coefficients du polynôme sont nuls et donc $h(t) = 0, t = 1, \dots, n$. On déduit $\mathbb{P}[h(T) = 0] = 1 \forall \theta \in (0, \infty)$.

Statistique complète

- La complétude est-elle pertinente pour la réduction des données ?

Proposition

Si T est complète, alors $h(T)$ est libre pour θ si et seulement si $h(T) = c$ presque sûrement.

Preuve

Soit $h(T)$ une statistique libre. Sa loi ne dépend pas de θ

Statistique complète

- ▶ La complétude est-elle pertinente pour la réduction des données ?

Proposition

Si T est complète, alors $h(T)$ est libre pour θ si et seulement si $h(T) = c$ presque sûrement.

Preuve

Soit $h(T)$ une statistique libre. Sa loi ne dépend pas de θ

Ainsi $\mathbb{E}[h(T)] = c$, pour une certaine constante c et donc

$\mathbb{E}[h(T) - c] = 0$. La complétude de T implique que $\mathbb{P}[h(T) = c] = 1$.

- ▶ Autrement dit : Il n'y a que les fonctions triviales (= constante) de T qui sont des statistiques libres.
- ▶ Une **statistique complète ne contient pas d'information libre**
- ▶ Une statistique exhaustive contient toute l'information pertinente alors qu'une statistique complète est épurée de toute information non-pertinente.

Statistique complète

Théorème de Basu

Une statistique exhaustive complète est **indépendante** de toute statistique libre.

Statistique complète

Théorème de Basu

Une statistique exhaustive complète est **indépendante** de toute statistique libre.

Preuve

On va s'intéresser au cas discret seulement. On pose T une statistique exhaustive complète et S libre. Il suffit de montrer que

$$\mathbb{P}[S(X) = s \mid T(X) = t] = \mathbb{P}[S(X) = s]$$

On définit $h(t) = \mathbb{P}[S(X) = s \mid T(X) = t] - \mathbb{P}[S(X) = s]$.

On remarque que

- ▶ $\mathbb{P}[S(X) = s]$ ne dépend pas de θ (libre)
- ▶ $\mathbb{P}[S(X) = s \mid T(X) = t] = \mathbb{P}[X \in \{x : S(x) = s\} \mid T = t]$ ne dépend pas de θ (à cause de exhaustivité).

Et h ne dépend pas de θ .

Ainsi pour tout $\theta \in \Theta$,

preuve (suite)

$$\begin{aligned}\mathbb{E}h(T) &= \sum_t (\mathbb{P}[S(X) = s \mid T(X) = t] - \mathbb{P}[S(X) = s])\mathbb{P}[T(X) = t] \\ &= \sum_t \mathbb{P}[S(X) = s \mid T(X) = t]\mathbb{P}[T(X) = t] \\ &\quad - \mathbb{P}[S(X) = s] \sum_t \mathbb{P}[T(X) = t] \\ &= \mathbb{P}[S(X) = s] - \mathbb{P}[S(X) = s] = 0.\end{aligned}$$

Or T est complète, donc $h(t) = 0$ pour tout t .

Le théorème de Basu est utile pour déduire l'indépendance entre deux statistiques.

- ▶ On n'en a pas besoin de calculer la loi jointe
- ▶ Besoin de montrer la complétude (souvent difficile)
- ▶ On va voir des modèles où il est facile de vérifier la complétude

Complétude et exhaustivité minimale

Théorème de Lehmann-Scheffé

Soit X de densité $f(x; \theta)$. Si $T(X)$ est exhaustive et complète pour θ alors T est exhaustive minimale.

Complétude et exhaustivité minimale

Théorème de Lehmann-Scheffé

Soit X de densité $f(x; \theta)$. Si $T(X)$ est exhaustive et complète pour θ alors T est exhaustive minimale.

Théorème

Si une statistique exhaustive minimale existe, alors toute statistique complète est aussi exhaustive minimale.