

# Estimation ponctuelle: Principes de base

Statistique mathématique  
M2 santé publique, université Paris-Sud

16 octobre 2018

# Estimation ponctuelle dans les familles paramétriques

Rappelons le point de départ :

- ▶ Collection de v.a (un vecteur aléatoire)  $X = (X_1, \dots, X_n)$
- ▶  $X \sim F_\theta \in \mathcal{F}$
- ▶  $\mathcal{F}$  une famille paramétrique de paramètre  $\theta \in \Theta \subseteq \mathbb{R}^d$

## Le problème de l'estimation ponctuelle

- ▶ Supposons que  $F$  est complètement définie par son paramètre  $\theta$  qui inconnu
- ▶ Soit  $(x_1, \dots, x_n)$  des réalisations de  $X \sim F_\theta$
- ▶ Estimer la valeur de  $\theta$  qui a *généré* les réalisations  $(x_1, \dots, x_n)$

# Estimation ponctuelle dans les familles paramétriques

- ▶ Approximation de la loi de  $g(X_1, \dots, X_n)$  quand  $n \uparrow \infty$ .
- ▶ L'information apportée par  $g(X_1, \dots, X_n)$ .
- ▶ Une famille générale de lois (modèles).

Aujourd'hui : Comment estimer  $\theta$  ? Des procédures générales ?

# Estimateur ponctuel

## Définition : estimateur

Soit  $\{F_\theta, \theta \in \Theta\}$  un modèle paramétrique où  $\Theta \subseteq \mathbb{R}^d$  et soit  $\mathbf{X} = (X_1, \dots, X_n) \sim F_\theta$  pour un certain  $\theta \in \Theta$ . Un estimateur ponctuel  $\hat{\theta}$  de  $\theta_0$  est une statistique  $T : \mathbb{R}^n \mapsto \Theta$ , dont le but est d'estimer  $\theta$ .

# Estimateur ponctuel

## Définition : estimateur

Soit  $\{F_\theta, \theta \in \Theta\}$  un modèle paramétrique où  $\Theta \subseteq \mathbb{R}^d$  et soit

$\mathbf{X} = (X_1, \dots, X_n) \sim F_\theta$  pour un certain  $\theta \in \Theta$ . Un estimateur ponctuel  $\hat{\theta}$  de  $\theta_0$  est une statistique  $T : \mathbb{R}^n \mapsto \Theta$ , dont le but est d'estimer  $\theta$ .

Toute statistique  $T : \mathbb{R}^n \mapsto \Theta$  est un estimateur potentiel !

→ Comment mesurer la qualité d'un estimateur ?

- ▶ Tout estimateur est une variable aléatoire.
- ▶ Un principe général, **bon** estimateur veut dire :

Loi( $\hat{\theta}$ ) se concentre autour de  $\theta$ .

→ Une description  $\infty$ -dimensionnelle de la qualité !

- ▶ A-t-on une mesure plus simple de la qualité ?

# Biais et erreur quadratique moyenne

## Définition (biais)

Le *biais* d'un estimateur  $\hat{\theta}$  de  $\theta \in \Theta$  est défini par

$$\text{biais}(\hat{\theta}) = \mathbb{E}_{\theta}[\hat{\theta}] - \theta$$

Cette quantité indique l'écart à la cible quand on utilise  $\hat{\theta}$

# Biais et erreur quadratique moyenne

## Définition (biais)

Le *biais* d'un estimateur  $\hat{\theta}$  de  $\theta \in \Theta$  est défini par

$$\text{biais}(\hat{\theta}) = \mathbb{E}_{\theta}[\hat{\theta}] - \theta$$

Cette quantité indique l'écart à la cible quand on utilise  $\hat{\theta}$

## Définition : estimateur sans biais

Un estimateur  $\hat{\theta}$  de  $\theta \in \Theta$  est sans biais si  $\mathbb{E}_{\theta}[\hat{\theta}] = \theta$ , i.e.  $\text{biais}(\hat{\theta}) = 0$ .

Nous verrons qu'il ne suffit pas d'avoir un estimateur sans biais !!!

# Biais et erreur quadratique moyenne

## Définition (biais)

Le *biais* d'un estimateur  $\hat{\theta}$  de  $\theta \in \Theta$  est défini par

$$\text{biais}(\hat{\theta}) = \mathbb{E}_{\theta}[\hat{\theta}] - \theta$$

Cette quantité indique l'écart à la cible quand on utilise  $\hat{\theta}$

## Définition : estimateur sans biais

Un estimateur  $\hat{\theta}$  de  $\theta \in \Theta$  est sans biais si  $\mathbb{E}_{\theta}[\hat{\theta}] = \theta$ , i.e.  $\text{biais}(\hat{\theta}) = 0$ .

Nous verrons qu'il ne suffit pas d'avoir un estimateur sans biais !!!

## Définition : erreur quadratique moyenne (MSE)

l'*erreur quadratique moyenne* d'un estimateur  $\hat{\theta}$  de  $\theta \in \Theta \subseteq \mathbb{R}$  est définie par

$$MSE(\hat{\theta}) = \mathbb{E}_{\theta}[(\hat{\theta} - \theta)^2]$$

# Biais et MSE

On utilise les notions de biais et de variance au lieu de concentration autour du paramètre :

- ▶ Le biais donne une indication sur la position de la loi de  $\hat{\theta}$  par rapport à  $\theta$  (si on considère la moyenne comme un bon estimateur de la position).
- ▶ Le MSE est une mesure de dispersion/position de  $\hat{\theta}$  autour de  $\theta$ .
- ▶ Si  $\hat{\theta}$  est sans biais pour  $\theta \in \mathbb{R}$  alors  $MSE(\hat{\theta}) = \text{Var}(\hat{\theta})$ .
- ▶ Pour  $\Theta \subseteq \mathbb{R}^d$ , nous avons  $MSE(\hat{\theta}) = \mathbb{E}_\theta \|\hat{\theta} - \theta\|^2$

# Exemple

## Exemple

Soit  $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2)$  et soit  $\hat{\mu} = \bar{X}$ . Alors

$$\mathbb{E}(\hat{\mu}) = \mu \text{ et } MSE(\hat{\mu}) = \text{Var}(\hat{\mu}) = \frac{\sigma^2}{n}.$$

Sur cet exemple, le biais et le MSE nous donnent une description complète de la concentration de la loi de  $\hat{\mu}$  autour de  $\mu$ .  $\hat{\mu}$  est gaussien donc sa loi est complètement définie par sa moyenne et sa variance.

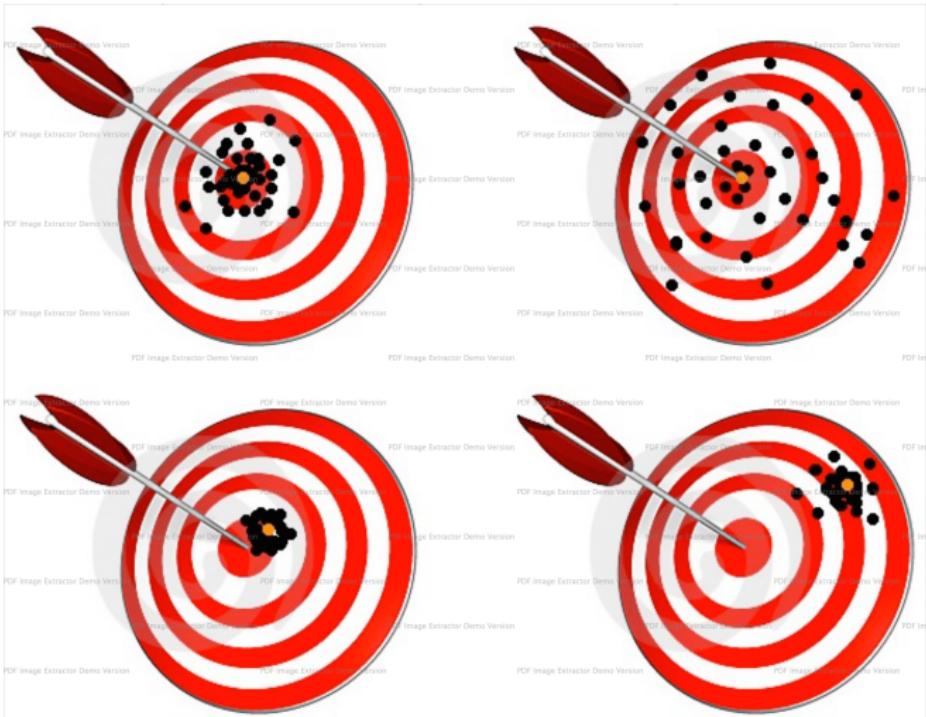
# Décomposition biais-variance du MSE

## Décomposition biais-variance du MSE

$$MSE(\hat{\theta}) = \text{Var}(\hat{\theta}) + \text{biais}^2(\hat{\theta})$$

- ▶ Une relation fondamentale et simple.
- ▶ Un petit MSE n'implique pas forcément une absence de biais.
- ▶ Parfois, des estimateurs biaisés sont meilleurs que des estimateurs sans biais.
- ▶ Compromis biais/variance (exemple : régression non paramétrique).

# Illustration



# Convergence

On peut aussi définir la qualité d'un estimateur quand  $n$  augmente !!!

## Convergence (on dit aussi consistance *Consistency*)

Une suite d'estimateur  $\{\hat{\theta}_n\}_{n \geq 1}$  de  $\theta \in \Theta$  est dite convergente si

$$\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta$$

- ▶ Un estimateur convergent (consistant) se concentre asymptotiquement autour de la vraie valeur de  $\theta$  quand la taille de l'échantillon  $n$  augmente.
- ▶ Une étude détaillée de la *qualité asymptotique* de  $\hat{\theta}_n$  nécessite l'étude de la loi de  $\hat{\theta}_n$  quand  $n \uparrow \infty$ .

# Estimateur plug-in (substitution) ou Méthode des moments

On cherche une procédure générale pour construire des estimateurs.

- idée :  $\theta \mapsto F_\theta$  est une bijection sous l'hypothèse d'**identifiabilité ?** du modèle
- ▶ Sous l'hypothèse d'identifiabilité  $\nu(F_\theta) = q(\theta)$  pour une certaine fonction  $q$  (penser à  $q(x) = x$  ou  $q(x) = x^2 \dots$ )

## Principe de substitution

Soit  $\nu = q(\theta) = \nu(F_\theta)$  le paramètre d'intérêt d'un modèle paramétrique  $\{F_\theta\}_{\theta \in \Theta}$ . Si on peut construire un estimateur  $\widehat{F}_\theta$  de  $F_\theta$  basé sur l'échantillon  $\mathbf{X} = (X_1, \dots, X_n)$ , alors on peut estimer  $\nu(F_\theta)$  par  $\nu(\widehat{F}_\theta)$ . Un tel estimateur est appelé estimateur par substitution *plug-in*.

## Estimateur plug-in

- ▶ En quelque sorte, on a inversé notre point de vue : on considère le paramètre  $\theta$  comme une fonction de  $F_\theta$  au lieu de voir  $F_\theta$  comme fonction de  $\theta$ !!!
- ▶ Notons que  $\theta = \theta(F_\theta)$  si  $q$  est la fonction identité.
- ▶ En pratique, un tel principe est utilisable quand on peut explicitement décrire **la fonctionnelle**  $F_\theta \mapsto \nu(F_\theta)$ .

# Quelques paramètres comme fonctionnelles de $F$

Exemples de paramètres fonctionnelles :

- ▶ La moyenne :

$$\mu(F) = \int_{-\infty}^{+\infty} x dF(x)$$

- ▶ La variance :

$$\sigma^2(F) = \int_{-\infty}^{+\infty} [x - \mu(F)]^2 dF(x)$$

- ▶ La médiane :  $\text{med}(F) = \inf \{x : F(x) \geq 1/2\}$
- ▶ On peut définir un paramètre  $\theta(F)$  indirectement

$$\int_{-\infty}^{+\infty} \psi(x - \theta(F)) dF(x) = 0.$$

- ▶ La densité (lorsque elle existe) en  $x_0$  :  $\theta(F) = \frac{d}{dx} F(x)|_{x=x_0}$

# La fonction de répartition empirique (la loi empirique)

## Principe de plug-in

Passer d'un problème d'estimation de  $\theta$  à un problème d'estimation de  $F$ .  
Mais comment ?

On considère le cas où  $\mathbf{X} = (X_1, \dots, X_n)$  iid. On peut définir la version empirique de la fonction de répartition  $F_X(\cdot)$  par

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{X_i \leq x\}.$$

# La fonction de répartition empirique (la loi empirique)

## Principe de plug-in

Passer d'un problème d'estimation de  $\theta$  à un problème d'estimation de  $F$ .  
Mais comment ?

On considère le cas où  $\mathbf{X} = (X_1, \dots, X_n)$  iid. On peut définir la version empirique de la fonction de répartition  $F_X(\cdot)$  par

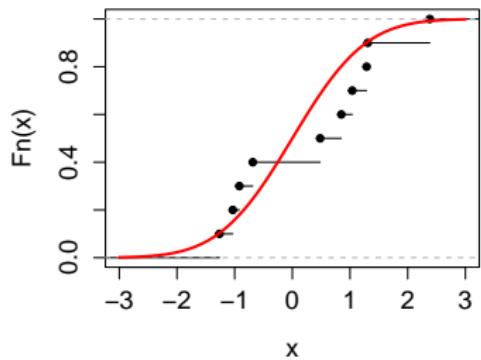
$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{X_i \leq x\}.$$

- ▶ Affecte une masse de  $1/n$  pour chaque observation
- ▶ Loi forte des grands nombres  $\Rightarrow \hat{F}_n(x) \xrightarrow{p.s.} F(x)$  pour tout  $x \in \mathbb{R}$ 
  - ↪ car les  $\mathbf{1}\{X_i \leq x\}$  sont des variables aléatoires iid Bernoulli( $F(x)$ )

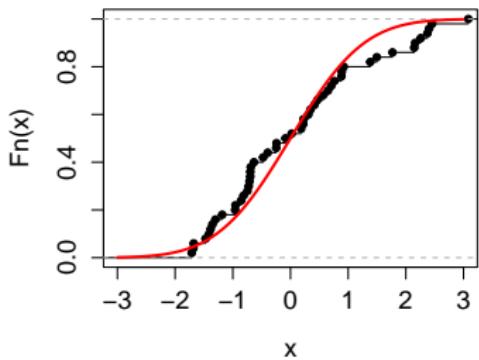
Cela suggère d'utiliser  $\nu(\hat{F}_n)$  comme estimateur de  $\nu(F)$  ...

# Fonction de répartition empirique

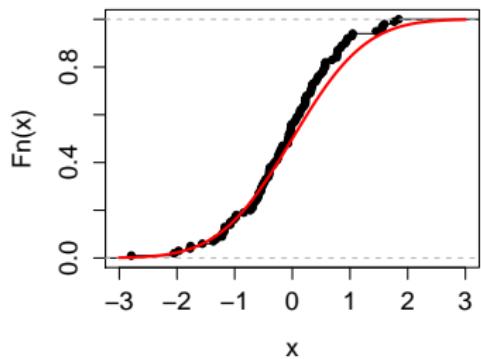
$n=10$



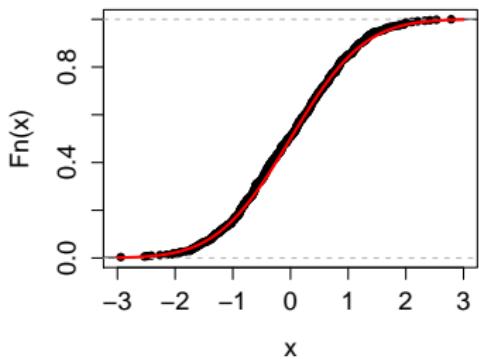
$n=50$



$n=100$



$n=500$



# Fonction de répartition empirique

On peut faire mieux que la convergence ponctuelle ....

## Glivenko-Cantelli

Soit  $X_1, \dots, X_n$  des variables aléatoires indépendantes, de loi  $F$ . Alors,  $\widehat{F}_n(y) = n^{-1} \sum_{i=1}^n \mathbf{1}\{X_i \leq y\}$  convergent uniformément vers  $F$  avec probabilité 1, i.e.

$$\sup_{x \in \mathbb{R}} |\widehat{F}_n(x) - F(x)| \xrightarrow{p.s.} 0$$

## Exemples

### Exemple (moyenne d'une fonction)

On considère  $\theta(F) = \int_{-\infty}^{+\infty} h(x)dF(x)$ . Un estimateur plug-in basé sur la fonction de répartition empirique est donné par

$$\hat{\theta} = \theta(\hat{F}_n) = \int_{-\infty}^{+\infty} h(x)d\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n h(X_i)$$

## Exemples

### Exemple (moyenne d'une fonction)

On considère  $\theta(F) = \int_{-\infty}^{+\infty} h(x)dF(x)$ . Un estimateur plug-in basé sur la fonction de répartition empirique est donné par

$$\hat{\theta} = \theta(\hat{F}_n) = \int_{-\infty}^{+\infty} h(x)d\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n h(X_i)$$

### Exemple (variance)

On considère maintenant  $\sigma^2(F) = \int_{-\infty}^{+\infty} [x - \mu(F)]^2 dF(x)$ . Nous avons

$$\sigma^2(\hat{F}_n) = \int_{-\infty}^{+\infty} x^2 d\hat{F}_n(x) - \left( \int_{-\infty}^{+\infty} x d\hat{F}_n(x) \right)^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \left( \frac{1}{n} \sum_{i=1}^n X_i \right)^2$$

# Méthode des moments

Une méthode ancienne (Karl Pearson, fin 1800's)

## Méthode des moments

Soit  $X_1, \dots, X_n$  un échantillon iid issu de  $F_\theta, \theta \in \mathbb{R}^p$ . L'estimateur  $\hat{\theta}$  par la méthode des moments de  $\theta$  est la solution en  $\theta$  des  $p$  équations

$$\int_{-\infty}^{+\infty} x^{k_j} \hat{F}_n(x) = \int_{-\infty}^{+\infty} x^{k_j} F_\theta(x), \quad \{k_j\}_{j=1}^p \subset \mathbb{N}$$

- ▶ C'est en quelque sorte un estimateur plug-in car on estime les moments théoriques par les moments empiriques et ensuite on estime  $\theta$ .
- ▶ Utile lorsqu'on en a pas de formule explicite de la fonctionnelle  $\theta(F)$ .

# Le problème des moments

## Théorème

Supposons que  $F$  est une loi déterminer par ses moments. Soit  $\{F_n\}_n$  une suite de loi telles que  $\int x^k dF_n(x) < \infty$  pour tout  $n$  et  $k$ . Alors,

$$\lim_{n \rightarrow \infty} \int x^k dF_n(x) = \int x^k F(x), \quad \forall k \geq 1 \Rightarrow F_n \xrightarrow{w} F.$$

# Le problème des moments

## Théorème

Supposons que  $F$  est une loi déterminer par ses moments. Soit  $\{F_n\}_n$  une suite de loi telles que  $\int x^k dF_n(x) < \infty$  pour tout  $n$  et  $k$ . Alors,

$$\lim_{n \rightarrow \infty} \int x^k dF_n(x) = \int x^k F(x), \quad \forall k \geq 1 \Rightarrow F_n \xrightarrow{w} F.$$

Mais toutes les lois ne sont pas déterminées par les moments!!!!

## Lemme

La loi de  $X$  est déterminée par ses moments s'il existe un voisinage ouvert  $A$  contenant 0 tel que

$$M_X(u) = \mathbb{E}\left[e^{-\langle u, X \rangle}\right] < \infty, \quad \forall u \in A.$$

## Exemple (loi exponentielle)

### Exemple

Soit  $X_1, \dots, X_n \stackrel{iid}{\sim} Exp(\lambda)$ . Alors  $\mathbb{E}[X_i^r] = \lambda^{-r}\Gamma(r+1)$ .

# Exemple (loi exponentielle)

## Exemple

Soit  $X_1, \dots, X_n \stackrel{iid}{\sim} Exp(\lambda)$ . Alors  $\mathbb{E}[X_i^r] = \lambda^{-r}\Gamma(r+1)$ .

On définit une classe d'estimateurs de  $\lambda$  qui dépendent de  $r$  donnés par

$$\hat{\lambda} = \left[ \frac{1}{n\Gamma(r+1)} \sum_{i=1}^n X_i^r \right]^{-\frac{1}{r}}.$$

Nous verrons qu'on peut choisir  $r$  pour avoir le "meilleur estimateur" ....

## Exemple (la loi gamma)

### La loi gamma

Soit  $X_1, \dots, X_n$  un échantillon issu d'une loi gamma de paramètres  $\alpha$  et  $\beta$ ,

$$f(x; \alpha, \beta) = \begin{cases} \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta} & \text{si } x > 0 \\ 0 & \text{sinon} \end{cases} \quad \text{où } \Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx.$$

On sait que  $\alpha > 0$ ,  $\beta > 0$ ,  $\mathbb{E}(X) = \alpha\beta$  et  $\text{Var}(X) = \alpha\beta^2$ .

## Exemple (la loi gamma)

### La loi gamma

Soit  $X_1, \dots, X_n$  un échantillon issu d'une loi gamma de paramètres  $\alpha$  et  $\beta$ ,

$$f(x; \alpha, \beta) = \begin{cases} \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta} & \text{si } x > 0 \\ 0 & \text{sinon} \end{cases} \quad \text{où } \Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx.$$

On sait que  $\alpha > 0$ ,  $\beta > 0$ ,  $\mathbb{E}(X) = \alpha\beta$  et  $\text{Var}(X) = \alpha\beta^2$ .

$$\hat{\alpha} = \frac{\bar{X}^2}{\hat{\sigma}^2} \text{ et } \hat{\lambda} = \frac{\bar{X}}{\hat{\sigma}^2}.$$

## Exemple : loi uniforme discrète

### Exemple

Soit  $X_1, \dots, X_n$  iid de loi  $\mathcal{U}\{1, \dots, \theta\}$  où  $\theta \in \mathbb{N}$ . Calculer  $\mathbb{E}(X)$  et proposer un estimateur  $\hat{\theta}$ .

## Exemple : loi uniforme discrète

### Exemple

Soit  $X_1, \dots, X_n$  iid de loi  $\mathcal{U}\{1, \dots, \theta\}$  où  $\theta \in \mathbb{N}$ . Calculer  $\mathbb{E}(X)$  et proposer un estimateur  $\hat{\theta}$ .

Avantage de la méthode des moments : elle peut être généralisée à des données non-iid.

# La fonction de vraisemblance

## Définition

Soit  $\mathbf{X} = (X_1, \dots, X_n)$  des variables aléatoires de densité jointe  $f(\mathbf{x}; \theta)$  (ou fonction de masse) où  $\theta \in \Theta \subseteq \mathbb{R}^p$ . La fonction de vraisemblance  $L(\theta)$  est la fonction aléatoire

$$L(\theta) = f(\mathbf{X}; \theta).$$

Notons qu'on considère  $L$  comme une fonction de  $\theta$  et pas de  $\mathbf{X}$ .  
Interprétation dans le cas discret ?

# La fonction de vraisemblance

## Définition

Soit  $\mathbf{X} = (X_1, \dots, X_n)$  des variables aléatoires de densité jointe  $f(\mathbf{x}; \theta)$  (ou fonction de masse) où  $\theta \in \Theta \subseteq \mathbb{R}^p$ . La fonction de vraisemblance  $L(\theta)$  est la fonction aléatoire

$$L(\theta) = f(\mathbf{X}; \theta).$$

Notons qu'on considère  $L$  comme une fonction de  $\theta$  et pas de  $\mathbf{X}$ .

Interprétation dans le cas discret ?

Lorsque  $\mathbf{X}$  est iid de densité  $f(\cdot; \theta)$ , alors la vraisemblance est

$$L(\theta) = \prod_{i=1}^n f(X_i; \theta).$$

# Estimateur du maximum de vraisemblance

## Définition (estimateur du maximum de vraisemblance)

Soit  $\mathbf{X} = (X_1, \dots, X_n)$  un échantillon aléatoire issu de  $F_\theta$ , et soit  $\hat{\theta}$  tel que

$$L(\hat{\theta}) \geq L(\theta), \quad \forall \theta \in \Theta.$$

Alors  $\hat{\theta}$  est appelé *un estimateur du maximum de vraisemblance* de  $\theta$ .

# Estimateur du maximum de vraisemblance

## Définition (estimateur du maximum de vraisemblance)

Soit  $\mathbf{X} = (X_1, \dots, X_n)$  un échantillon aléatoire issu de  $F_\theta$ , et soit  $\hat{\theta}$  tel que

$$L(\hat{\theta}) \geq L(\theta), \quad \forall \theta \in \Theta.$$

Alors  $\hat{\theta}$  est appelé *un estimateur du maximum de vraisemblance* de  $\theta$ .

On appelle  $\hat{\theta}$  l' estimateur du maximum de vraisemblance, s'il est l'unique maximum de  $L(\theta)$ ,

$$\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} L(\theta).$$