

Exercice : (décomposition biais - variance) :

Montrer que :

$$\underbrace{\mathbb{E}[\|X\beta - X\hat{\beta}\|_2^2]}_{\text{Risque}} = \underbrace{\left(\|\mathbb{E}[X\hat{\beta}] - X\beta\|_2\right)^2}_{\text{biais}^2} + \underbrace{\mathbb{E}[\|X\hat{\beta} - \mathbb{E}[X\hat{\beta}]\|_2^2]}_{\text{variance}}$$

Exercice : (régression ridge) :

$$l(\beta) = \|y - X\beta\|_2^2 + \lambda \|\beta\|_2^2$$

Montrer que $\underset{\beta \in \mathbb{R}^p}{\operatorname{argmin}} l(\beta) = (X^T X + \lambda I_p)^{-1} X^T y$

indication :

$$\begin{cases} \frac{\partial}{\partial x} (x^T c) = \frac{\partial}{\partial x} (c^T x) = c \\ \frac{\partial}{\partial x} (x^T A x) = (A + A^T) x \end{cases}$$

Montrer que $(X^T X + \lambda I_p) \succ 0$ (définie strictement positive)
conclure ??

Exercice : (ridge)

Montrer que la régression ridge revient à faire une régression linéaire multiple en augmentant les lignes de X et le vecteur y . Préciser cette augmentation.

Exercice (ridge) :

On s'intéresse à la régression ridge avec une seule variable explicative et on obtient un coefficient égal à a .

On ajoute une variable $X^* = X$ la copie exacte de X .

- Déduire le coefficient de régression ridge de X et X^* en fonction de a .
- Même question si on augmente X de m colonnes identiques à X .

Exercice (convexité des moindres carrés)

$f: \mathbb{R}^p \rightarrow \mathbb{R}$ est convexe SSI

pour tout
 $w \in [0, 1]$

$$f[wa + (1-w)b] \leq wf[a] + (1-w)f[b]$$

et $a, b \in \mathbb{R}^p$

- 1- Montrer que $f: a \mapsto \|y - Xa\|_2^2$ est convexe
- 2- " " " f est strictement convexe SSI $X^T X$ est inversible.

Exercice (Point de vue Bayésien de ridge et LASSO):

On considère le modèle linéaire

$$y = X\beta + u \quad \left\{ \begin{array}{l} y \in \mathbb{R}^n, X \in \mathbb{R}^{n \times p} \\ \beta \in \mathbb{R}^p \end{array} \right.$$

Le bruit $u \sim \mathcal{N}_n[\mu_n, \sigma^2 I_{n \times n}]$

$$y \sim \mathcal{N}_n(X\beta, \sigma^2 I_{n \times n})$$

Cadre Bayésien: se donner une loi a priori de β , on peut se minimiser des données sachant le paramètre β .

$$y|\beta \sim \mathcal{N}_n(X\beta, \sigma^2 I_{n \times n}),$$

On va étudier l'estimateur du maximum a posteriori

$$\hat{\beta}_{\text{map}} \in \underset{\beta \in \mathbb{R}^p}{\operatorname{argmax}} \ell[\beta|y]$$

où la "vraisemblance a posteriori" $l[\beta|y]$ est le log de la densité de y comme une fonction de β .

On suppose que le vecteur de coefficients de régression β est indépendant du bruit u et densité g .

$l[\beta|y]$ est proportionnelle à $f(y)g(\beta)$

où f_β est la densité de $\mathcal{N}_n(X\beta, \sigma^2 I_{n \times n})$.

Nous allons établir l'équivalence entre l'estimateur $\hat{\beta}_{\text{map}}$ et les estimateurs fréquentistes $\hat{\beta}_{\text{ridge}}$ et $\hat{\beta}_{\text{Lasso}}$

1. Montrer que lorsque $p \sim \mathcal{N}_p(0_p, \tau^2 I_{p \times p})$, $\hat{\beta}_{\text{map}}$ coïncide avec

$$\hat{\beta}_{\text{ridge}} \in \underset{\beta \in \mathbb{R}^p}{\operatorname{argmin}} \left\{ \|y - X\beta\|_2^2 + \lambda \|\beta\|_2^2 \right\}$$

$$\text{avec } \lambda = \frac{\sigma^2}{\tau^2}.$$

2. Montrer que lorsque p suit une loi de Laplace multivariée de densité $\frac{e^{-\frac{\|\beta\|_1}{\tau}}}{(2\tau)^p}$, l'estimateur

$\hat{\beta}_{\text{map}}$ coïncide avec

$$\hat{\beta}_{\text{Lasso}} \in \underset{\beta \in \mathbb{R}^p}{\operatorname{argmin}} \left\{ \|y - X\beta\|_2^2 + \lambda \|\beta\|_1 \right\} \text{ avec } \lambda = \frac{2\sigma^2}{\tau}.$$

Exercice (elasticnet vs LASSO):

On considère la régression elasticnet

$$\min_{\beta} \|y - X\beta\|^2 + \lambda \left(\alpha \|\beta\|_2^2 + (1 - \alpha) \|\beta\|_1 \right)$$

- Montrer que la régression elasticnet revient à faire une régression LASSO avec une version augmentée de X et y .