

Exercice (décomposition biais - variance):

$$\begin{aligned} \mathbb{E}[\|X\beta - \hat{X}\hat{\beta}\|_2^2] &= \mathbb{E}\left[\underbrace{\|X\beta - \mathbb{E}[X\hat{\beta}]\|_2^2}_a + \underbrace{\|\mathbb{E}[X\hat{\beta}] - \hat{X}\hat{\beta}\|_2^2}_b\right] \\ &= \mathbb{E}\left[\|X\beta - \mathbb{E}[X\hat{\beta}]\|_2^2 + 2\langle X\beta - \mathbb{E}[X\hat{\beta}], \mathbb{E}[X\hat{\beta}] - \hat{X}\hat{\beta} \rangle\right. \\ &\quad \left.+ \|\mathbb{E}[X\hat{\beta}] - \hat{X}\hat{\beta}\|_2^2\right] \\ &= \underbrace{\mathbb{E}[\|X\beta - \mathbb{E}[X\hat{\beta}]\|_2^2]}_{\text{Biais}^2} + 2\mathbb{E}\left[\langle X\beta - \mathbb{E}[X\hat{\beta}], \mathbb{E}[X\hat{\beta}] - \hat{X}\hat{\beta} \rangle\right] \\ &\quad + \underbrace{\mathbb{E}[\|\hat{X}\hat{\beta} - \mathbb{E}[X\hat{\beta}]\|_2^2]}_{\text{Variance}} \end{aligned}$$

Notons aussi ici :

$$2\mathbb{E}\left[\underbrace{\langle X\beta - \mathbb{E}[X\hat{\beta}] \rangle}_{\uparrow \text{non aléatoire}}, \underbrace{\mathbb{E}[X\hat{\beta}] - \hat{X}\hat{\beta}}_{\uparrow \text{non aléatoire}}\right] = 0.$$

Exercice (ridge):

on écrit $\tilde{X} = \begin{bmatrix} X \\ \sqrt{\lambda} I_p \end{bmatrix}$ et $y = \begin{bmatrix} y \\ 0_p \end{bmatrix}$

I_p : identité $p \times p$. 0_p : $p \times 1$ de zéros

$$\tilde{X}^T \tilde{X} = \begin{bmatrix} X^T & \sqrt{\lambda} I_p \end{bmatrix} \begin{bmatrix} X \\ \sqrt{\lambda} I_p \end{bmatrix} = X^T X + \lambda I_p$$

et $\tilde{X}^T y = (X^T \cdot \sqrt{\lambda} I_p) = X^T y.$

$$\begin{aligned} \hat{\beta} &= (\tilde{X}^T \tilde{X} + \lambda I_p)^{-1} \tilde{X}^T y \\ &= (X^T X + \lambda I_p)^{-1} X^T y. \end{aligned}$$

Exercice (ridge):

$X \in \mathbb{R}^{m \times 1}$ et $a = \hat{\beta} = \frac{X^T y}{X^T X + \lambda}$.

Lorsque une copie $X^* = X$ est ajoutée, on veut résoudre

$$\min_{(\beta_1, \beta_2) \in \mathbb{R}^2} \|y - \underbrace{X^T \beta_1 - X^{*T} \beta_2}_= \|_2^2 + \lambda \|\beta_1\|_2^2 + \lambda \|\beta_2\|_2^2$$

Par symétrie, on sait que $\beta_1 = \beta_2$ solution de

$$\min_{\beta} \|y - 2 X^T \beta\|_2^2 + 2 \lambda \|\beta\|_2^2$$

$$\hat{\beta}_1 = \hat{\beta}_2 = \frac{X^T y}{2 X^T X + \lambda}$$

$m \geq 2$

$$\hat{\beta}_k = \frac{X^T y}{m X^T X + \lambda}, \quad k = 1, \dots, m.$$

Exercice (régression ridge):

$$l(\beta) = [y - X\beta]^T [y - X\beta] + \lambda \beta^T \beta$$

$$= y^T y - \beta^T X^T y - y^T X \beta + \beta^T X^T X \beta + \lambda \beta^T \beta$$

$$= y^T y - \beta^T X^T y - \beta^T X^T y + \beta^T X^T X \beta + \beta^T [\lambda I_p] \beta$$

$$= y^T y - 2 \beta^T X^T y + \beta^T [X^T X + \lambda I_p] \beta$$

$$\frac{\partial l(\beta)}{\partial \beta} = -2 X^T y + 2 (X^T X + \lambda I_p) \beta = 0$$

$$= [X^T X + \lambda I_p] \beta = X^T y$$

$$(c) \quad \hat{\beta}_{\text{ridge}} = [X^T X + \lambda I_p]^{-1} X^T y$$

Montrons que si $\lambda > 0$ alors $(X^T X + \lambda I_p) \succ 0$

Soit $a \in \mathbb{R}^p \setminus \{0\}$

$$a^T (X^T X + \lambda I_p) a = a^T X^T X a + \lambda a^T I_p a$$

$$= a^T X^T X a + \lambda \|a\|_2^2 \geq 0 \quad (\text{inversible}).$$

Exercice (Convexité des moindres carrés):

1) $f: a \mapsto \|y - Xa\|_2^2 \quad a \in \mathbb{R}^p$
 soit $w \in [0, 1]$ et $a, b \in \mathbb{R}^p$

$$\begin{aligned} & f[wa + (1-w)b] - w f[a] - (1-w) f[b] \\ &= \|y - X(wa + (1-w)b)\|_2^2 - w \|y - Xa\|_2^2 - (1-w) \|y - Xb\|_2^2 \\ &= \|w(y - Xa) + (1-w)(y - Xb)\|_2^2 - w \|y - Xa\|_2^2 - (1-w) \|y - Xb\|_2^2 \\ &= \|w(y - Xa)\|_2^2 + \|(1-w)(y - Xb)\|_2^2 + 2 \langle w(y - Xa), (1-w)(y - Xb) \rangle \\ &\quad - w \|y - Xa\|_2^2 - (1-w) \|y - Xb\|_2^2 \quad (\|a+b\|_2^2 = \|a\|_2^2 + \|b\|_2^2 + 2\langle a, b \rangle) \\ &= w^2 \|y - Xa\|_2^2 + (1-w)^2 \|y - Xb\|_2^2 + 2w(1-w) \langle y - Xa, y - Xb \rangle \\ &\quad - w \|y - Xa\|_2^2 - (1-w) \|y - Xb\|_2^2 \\ &= w^2 (\|y - Xa\|_2^2 + \|y - Xb\|_2^2 - 2 \langle y - Xa, y - Xb \rangle) \\ &\quad - w (\|y - Xa\|_2^2 + \|y - Xb\|_2^2 - 2 \langle y - Xa, y - Xb \rangle) \\ &= w^2 \|y - Xa - (y - Xb)\|_2^2 - w \|y - Xa - (y - Xb)\|_2^2 \\ &= (w^2 - w) \|Xb - Xa\|_2^2 \leq 0. \end{aligned}$$

2) $\frac{\partial^2}{\partial p^2} \|y - Xp\|_2^2 = 2X^T X \Rightarrow f \text{ est strictement}$
 Convexe SSI
 $X^T X \succ 0$.

Exercice (point de vue Bayésien de Ridge et LASSO)

Ce n'est que du calcul:

$$1. f_p(y) = \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{\|y - X\beta\|_2^2}{2\sigma^2}}$$

$$\text{et } g(\beta) = \frac{1}{(2\pi\tau^2)^{p/2}} e^{-\frac{\|\beta\|_2^2}{2\tau^2}}$$

Nous avons:

$$\log[f_p(y) g(\beta)] = \log\left[\frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{\|y - X\beta\|_2^2}{2\sigma^2}} \times \frac{e^{-\frac{\|\beta\|_2^2}{2\tau^2}}}{(2\pi\tau^2)^{p/2}}\right]$$

$$= -\frac{n}{2} \log[2\pi\sigma^2] - \frac{1}{2\sigma^2} \|y - X\beta\|_2^2 - \frac{p}{2} \log[2\pi\tau^2] - \frac{1}{2\tau^2} \|\beta\|_2^2$$

$$\underline{\text{Ainsi, }} \arg\max_{\beta \in \mathbb{R}^p} \ell[\beta|y] = \arg\min_{\beta \in \mathbb{R}^p} \left\{ \frac{n}{2} \log[2\pi\sigma^2] + \frac{\|y - X\beta\|_2^2}{2\sigma^2} + \frac{p}{2} \log(2\pi\tau^2) + \frac{1}{2\tau^2} \|\beta\|_2^2 \right\}$$

$$= \arg\min_{\beta \in \mathbb{R}^p} \left\{ \frac{\|y - X\beta\|_2^2}{2\sigma^2} + \frac{1}{2\tau^2} \|\beta\|_2^2 \right\}$$

$$= \arg\min_{\beta \in \mathbb{R}^p} \left\{ \|y - X\beta\|_2^2 + \frac{\sigma^2}{\tau^2} \|\beta\|_2^2 \right\}$$

2) on pose $g[\beta] = \frac{1}{(2\sigma)^p} e^{-\frac{\|\beta\|_1}{\sigma}}$

$$\log \left[\frac{f(y)}{p} g[\beta] \right] = \log \left[\frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{\|y - X\beta\|_2^2}{2\sigma^2}} \times \frac{e^{-\frac{\|\beta\|_1}{\sigma}}}{(2\sigma)^p} \right]$$

$$= \frac{-n}{2} \log[2\pi\sigma^2] - \frac{1}{2\sigma^2} \|y - X\beta\|_2^2 - p \log[2\sigma] - \frac{1}{\sigma} \|\beta\|_1$$

$$\arg\max_{\beta \in \mathbb{R}^p} \ell[\beta|y] = \arg\min_{\beta \in \mathbb{R}^p} \left\{ \frac{n}{2} \log(2\pi\sigma^2) + \frac{\|y - X\beta\|_2^2}{2\sigma^2} + p \log(2\sigma) + \frac{\|\beta\|_1}{\sigma} \right\}$$

$$= \arg\min_{\beta \in \mathbb{R}^p} \left\{ \frac{\|y - X\beta\|_2^2}{2\sigma^2} + \frac{\|\beta\|_1}{\sigma} \right\}$$

$$= \arg\min_{\beta \in \mathbb{R}^p} \left\{ \|y - X\beta\|_2^2 + \frac{2\sigma^2}{\sigma} \|\beta\|_1 \right\}.$$

3. En général, nous avons :

$$\hat{\beta}_{\text{map}} \in \arg\min_{\beta \in \mathbb{R}^p} \left\{ \|y - X\beta\|_2^2 - 2\sigma^2 \log g[\beta] \right\}$$

Exercice (elasticnet vs LASSO):

On suppose que $y \in \mathbb{R}^{n \times 1}$ et $X \in \mathbb{R}^{n \times (p+1)}$ et $\beta \in \mathbb{R}^{(p+1) \times 1}$.

On augmente X par :

$$\tilde{X} = \begin{pmatrix} X \\ \gamma I_{p+1} \end{pmatrix} \in \mathbb{R}^{(n+p+1) \times (p+1)}$$

avec $\gamma > 0$.

$$\tilde{y} = \begin{pmatrix} y \\ 0_{p+1} \end{pmatrix} \in \mathbb{R}^{(n+p+1) \times 1}$$

Nous avons alors :

$$\|\tilde{y} - \tilde{X}\beta\|_2^2 = \left\| \begin{pmatrix} y - X\beta \\ \gamma\beta \end{pmatrix} \right\|_2^2 = \|y - X\beta\|_2^2 + \gamma^2 \|\beta\|_2^2$$

On considère la régression LASSO pour (\tilde{y}, \tilde{X})

$$\min_{\beta} \|\tilde{y} - \tilde{X}\beta\|_2^2 + \delta \|\beta\|_1 = \min_{\beta} \|y - X\beta\|_2^2 + \gamma \|\beta\|_2^2 + \delta \|\beta\|_1$$

On choisit $\gamma = \sqrt{\lambda\alpha}$ et $\delta = \lambda(1-\alpha)$, on obtient le problème elasticnet de départ.

