

Introduction

masedki.github.io



lun. 23 mars 2020

Outline

1. Introduction


2. Régression vs classification supervisée

Références



Problème d'apprentissage

0	0	0	0	0
1	1	1	1	1
2	2	2	2	2
3	3	3	3	3
4	4	4	4	4
5	5	5	5	5
6	6	6	6	6
7	7	7	7	7
8	8	8	8	8
9	9	9	9	9



- Reconnaissance de chiffres
manuscrits ? 0, 1, 2 ... ?

Problèmes d'apprentissage statistique

- Identifier les facteurs de risque du cancer de la prostate
- Classifier des phonèmes à partir de périodogrammes
- Prédire si une personne est sujette aux crises cardiaques, à partir de mesures cliniques, son régime et des données démographiques
- Personnaliser un système de détection de spam email
- Lecture de codes postaux écrits à la main
- Classification d'échantillons de tissus dans différents types de cancer, en fonction de données d'expression de gènes
- Établir une relation entre salaires et variables démographiques
- Classifier les pixels d'une image satellite

Question

- Sur 4 601 mails, on a pu identifier 1813 spams.
- On a également mesuré sur chacun de ces mails la présence ou absence de 57 mots.

Peut-on construire à partir de ces données une méthode de détection automatique de spam ?

Outline

1. Introduction

2. Régression vs classification supervisée

Réprésentation du problème

- La plupart de ces problèmes peuvent être appréhendés dans un contexte de **régression** : on cherche à expliquer une variable Y par d'autres variables dites explicatives X_1, \dots, X_p :

Y	X
Chiffre	image
Mot	courbe
Spam ou pas	présence/absence d'un ensemble mots
Type de leucémie	expressions de gènes

- Lorsque la variable à expliquer est quantitative, on parle de **régression**.
- Lorsqu'elle est qualitative, on parle de **discrimination** ou **classification supervisée**.

Régression

- Un **échantillon i.i.d d'apprentissage** $(X_1, Y_1), \dots, (X_n, Y_n)$ d'une loi conjointe \mathbb{P} **inconnue** sur $\mathbb{R}^p \times \mathbb{R}$.
- **Objectif** : Prédire ou expliquer la variable Y à partir d'une nouvelle observation X .
- **Méthode** : construire une règle de prédiction (**ou régression**)

$$m : \mathbb{R}^p \mapsto \mathbb{R}.$$

- Soit $l : \mathbb{R} \times \mathbb{R} \mapsto \mathbb{R}_+$ une fonction de perte (i.e, $l(y, y') = 0$ et $l(y, y') > 0$ pour $y \neq y'$), par exemple

$$l(y, y') = |y - y'|^q$$

(perte absolue si $q = 1$ et perte quadratique $q = 2$).

Risque ou erreur de généralisation

- Le **risque** ou erreur de généralisation d'une règle de décision (ou prédiction) m est défini par

$$R_{\mathbb{P}}(m) = \mathbb{E}_{(X,Y)} \left[l(Y, m(X)) \right].$$

La fonction de régression

- Un **champion**

$$m^*(x) = \mathbb{E}[Y|X = x]$$

appelé **fonction de régression**.

- Pour toute autre fonction m , on a

$$\mathbb{E} \left[(Y - m^*(X))^2 \right] \leq \mathbb{E} \left[(Y - m(X))^2 \right]$$

.

La fonction de régression

Nous avons

$$\mathbb{E}_{X,Y} \left[\left(Y - m(X) \right)^2 \right] = \mathbb{E}_X \mathbb{E}_{Y|X} \left[\left(Y - m(X) \right)^2 \mid X \right]$$

Donc il suffit de minimiser cette erreur ponctuellement en X

$$m(x) = \operatorname{argmin}_c \mathbb{E}_{Y|X} \left[\left(Y - c \right)^2 \mid X = x \right].$$

La solution est donnée par

$$m^*(x) = \mathbb{E}[Y \mid X = x]$$

La classification binaire

- Un **échantillon i.i.d d'apprentissage** $(X_1, Y_1), \dots, (X_n, Y_n)$ d'une loi conjointe \mathbb{P} **inconnue** sur $\mathbb{R}^p \times \{0, 1\}$.
- **Objectif** : Prédire ou expliquer la variable Y à partir d'une nouvelle observation X .
- **Méthode** : construire une **règle classification** (ou décision)

$$g : \mathbb{R}^p \mapsto \{0, 1\}.$$

- La fonction de perte binaire $l(y, y') = \mathbb{1}_{y \neq y'}$.
 - **Risque** associé à g : **taux de mauvais classement**

$$R_{\mathbb{P}}(g) = \mathbb{E} \left[l(g(X), Y) \right] = \mathbb{P}(g(X) \neq Y).$$

La règle de Bayes

- Un **champion** appelé **règle de Bayes**

$$g^*(x) = \begin{cases} 1 & \text{si } \eta(x) \geq \frac{1}{2} \\ 0 & \text{sinon,} \end{cases}$$

où $\eta(x) = \mathbb{P}(Y = 1|X = x)$.

- Quelque soit la règle de décision g , nous avons

$$R_{\mathbb{P}}(g^*) = \mathbb{P}(g^*(X) \neq Y) \leq \mathbb{P}(g(X) \neq Y) = R_{\mathbb{P}}(g).$$

Règle de Bayes : un théorème

Pour toute règle de classification $g : \mathcal{X} \mapsto \mathcal{Y}$, pour la fonction de perte binaire, nous avons

$$R(g) - R(g^*) = \mathbb{E}_X \left[\mathbb{1} \left\{ g(X) \neq g^*(X) \right\} |2\eta(X) - 1| \right].$$

- Interpréter ce résultat lorsque

$$\eta(x) = \frac{1}{2}, \forall x \in \left\{ x \in \mathcal{X} : g(x) \neq g^*(x) \right\}$$

Début de preuve

On remarque que :

$$\begin{aligned}\mathbb{E}_{Y|X=x} \left[\mathbb{1}\{Y = g^*(x)\} \right] &= \mathbb{P}_{Y|X}[Y = g^*(x)] \\ &= \begin{cases} \eta(x) & \text{si } \eta(x) \geq \frac{1}{2} \\ 1 - \eta(x) & \text{sinon} \end{cases} \\ &= \frac{1}{2} + \left| \eta(x) - \frac{1}{2} \right|.\end{aligned}$$

Rappel :

$$\mathbb{E}_{X,Y} h(X, Y) = \mathbb{E}_X \mathbb{E}_{Y|X} h(X, Y).$$

suite de la preuve : voir [notes](#)

Proposition

$$R^* = R(g^*) = \mathbb{E}_X \left[\min \left\{ \eta(X), 1 - \eta(X) \right\} \right]$$

Preuve : voir [notes](#) !!

Problème majeur !!

- **Problème:** m^* est inconnu en pratique. Il faut construire un régresseur \widehat{m}_n à partir des données $(X_1, Y_1), \dots, (X_n, Y_n)$, tel que

$$\widehat{m}_n(x) \approx m^*(x).$$

- **Problème:** g^* est inconnue en pratique. Il faut construire une règle \widehat{g}_n à partir des données $(X_1, Y_1), \dots, (X_n, Y_n)$, tel que

$$\widehat{g}_n(x) \approx g^*(x).$$

Un candidat naturel

- À partir des expressions de m^* et g^* , proposer deux estimateurs intuitifs.

Décomposition de l'erreur

Pour tout estimateur $\widehat{m}_n(x)$ de $m^*(x)$ à x fixé, nous avons

$$\begin{aligned}\mathbb{E}\left[\left(m^*(x) - \widehat{m}_n(x)\right)^2\right] &= [m^*(x)]^2 - 2m^*(x)\mathbb{E}[\widehat{m}_n(x)] \\ &\quad + \mathbb{E}\left[(\widehat{m}_n(x))^2\right] \\ &= \left[m^*(x) - \mathbb{E}(\widehat{m}_n(x))\right]^2 \\ &\quad + \mathbb{E}\left[(\widehat{m}_n(x))^2\right] - \left[\mathbb{E}(\widehat{m}_n(x))\right]^2 \\ &= (\text{biais})^2 + \text{Var}[\widehat{m}_n(x)]\end{aligned}$$

Notations

- On s'intéresse au cas où on cherche à expliquer une variable qualitative Y par p variables explicatives X_1, \dots, X_p .
- Y est à valeurs dans un ensemble discret fini de modalités qui peuvent être numérotées par des indices $\{1, 2, \dots, K\}$ et les variables X_1, \dots, X_p peuvent être qualitatives et/ou quantitatives.
- Néanmoins, pour présenter les méthodes, on se restreint au cas où Y est à 2 modalités (0 et 1).

Table of Contents

1. Introduction

2. Régression vs classification supervisée