

# Probabilités

Moh. Sedki

Université Paris-Sud

24 septembre 2017

# Notions d'événement en probabilité

Événement **certain**  $\Omega$  toujours réalisé, **impossible**  $\emptyset$  jamais réalisé

## Composition d'événements

- ▶ **Négation** d'un événement  $\bar{A} = \Omega \setminus A$  réalisé ssi  $A$  n'est pas réalisé
- ▶ **Union** d'événements  $A \cup B$  :  $A$  est réalisé ou  $B$  est réalisé
- ▶ **Intersection** d'événements  $A \cap B$  :  $A$  est réalisé et  $B$  est réalisé

## Relation entre événements

- ▶ **Inclusion**  $A \subset B$  : si  $A$  est réalisé,  $B$  l'est aussi
- ▶ **Egalité**  $A = B$
- ▶ **Incompatibilité**  $A \cap B = \emptyset$  (on dit aussi événements disjoints)

$A$  et  $\bar{A}$  sont incompatibles car  $A \cap \bar{A} = \emptyset$  ; de plus,  $A \cup \bar{A} = \Omega$

# Algèbre des événements

Idempotence

$$A \cup A = A, \quad A \cap A = A$$

Commutativité

$$A \cup B = B \cup A, \quad A \cap B = B \cap A$$

Associativité

$$(A \cup B) \cup C = A \cup (B \cup C) = A \cup B \cup C$$
$$(A \cap B) \cap C = A \cap (B \cap C) = A \cap B \cap C$$

Distributivité

$$(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$$
$$(A \cap B) \cup C = (A \cup C) \cap (B \cup C)$$

Identités

$$A \cup \emptyset = A, \quad A \cup \Omega = \Omega$$
$$A \cap \emptyset = \emptyset, \quad A \cap \Omega = A$$

Complémentarité

$$\overline{(\bar{A})} = A, \quad \bar{\emptyset} = \Omega, \quad \bar{\Omega} = \emptyset$$

Lois de De Morgan

$$\overline{A \cup B} = \bar{A} \cap \bar{B}, \quad \overline{A \cap B} = \bar{A} \cup \bar{B}$$

# Système d'événements

Soient  $n$  événements  $A_1, A_2, \dots, A_n$  ;  $\left(\bigcap_{i=1}^n A_i\right) \subset \left(\bigcup_{i=1}^n A_i\right)$

► **Intersection**  $\bigcap_{i=1}^n A_i = A_1 \cap A_2 \cap \dots \cap A_n$

tous les événements sont réalisés en même temps

► **Union**  $\bigcup_{i=1}^n A_i = A_1 \cup A_2 \cup \dots \cup A_n$

au moins l'un des événements est réalisé

L'ensemble  $\{A_i\}_{i=1,2,\dots,n}$  d'événements est une **partition** (dit aussi **système complet d'événements** ou **événements exhaustifs**) ssi

►  $\forall i, A_i \neq \emptyset$

aucun événement impossible

►  $\forall i \neq j, A_i \cap A_j = \emptyset$

événements incompatibles 2 à 2

►  $\bigcup_{i=1}^n A_i = \Omega$

# Calculs de probabilités

Probabilité d'un événement  $A$  :  $\mathbb{P}(A) = \frac{\#A}{\#\Omega}$ ,  $0 \leq \mathbb{P}(A) \leq 1$

$$\mathbb{P}(\Omega) = 1, \quad \mathbb{P}(\emptyset) = 0$$

**Formule de Poincaré** :  $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$

Si  $A$  et  $B$  sont 2 événements incompatibles ( $A \cap B = \emptyset$ ), alors  $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$ ; en particulier,  $\mathbb{P}(\bar{A}) = 1 - \mathbb{P}(A)$

De façon générale,  $\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \mathbb{P}(A_i)$ , l'égalité n'étant vérifiée que pour des événements incompatibles

**Formule des probabilités totales** : Si  $B_1, \dots, B_n$  forment une partition de  $\Omega$ , alors  $\mathbb{P}(A) = \mathbb{P}(A \cap B_1) + \dots + \mathbb{P}(A \cap B_n)$   
En particulier,  $\mathbb{P}(A) = \mathbb{P}(A \cap B) + \mathbb{P}(A \cap \bar{B})$

# Probabilité conditionnelle

**Définition :**  $\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$  avec  $\mathbb{P}(B) \neq 0$   
probabilité de réaliser  $A$  sachant que  $B$  a été réalisé

## Propriétés

- ▶  $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B|A) = \mathbb{P}(B)\mathbb{P}(A|B)$  pour  $\mathbb{P}(A) > 0, \mathbb{P}(B) > 0$
- ▶  $\mathbb{P}(\bar{A}|B) = 1 - \mathbb{P}(A|B)$

**Théorème des probabilités totales :** Si  $\{B_1, \dots, B_n\}$  est une partition de  $\Omega$ , alors  $\mathbb{P}(A) = \sum_{i=1}^n \mathbb{P}(A|B_i)\mathbb{P}(B_i)$

**Théorème de Bayes :**  $\mathbb{P}(A|B) = \frac{\mathbb{P}(B|A)\mathbb{P}(A)}{\mathbb{P}(B|A)\mathbb{P}(A) + \mathbb{P}(B|\bar{A})\mathbb{P}(\bar{A})}$

# Indépendance et indépendance conditionnelle

$A \perp B$  :  $A$  et  $B$  sont indépendants

ssi  $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$

ssi  $\mathbb{P}(A|B) = \mathbb{P}(A)$  pour  $\mathbb{P}(B) > 0$

ssi  $\mathbb{P}(B|A) = \mathbb{P}(B)$  pour  $\mathbb{P}(A) > 0$

(la connaissance de  $A$  n'altère pas celle de  $B$ , et réciproquement)

**Ne pas confondre** avec  $\mathbb{P}(A \cap B) = 0 \Leftrightarrow A$  et  $B$  disjoints

$(A \perp B)|C$  :  $A$  et  $B$  sont indépendants conditionnellement à  $C$

ssi  $\mathbb{P}(A \cap B|C) = \mathbb{P}(A|C)\mathbb{P}(B|C)$

ssi  $\mathbb{P}(A|B, C) = \mathbb{P}(A|B \cap C) = \mathbb{P}(A|C)$  pour  $\mathbb{P}(B) > 0$

ssi  $\mathbb{P}(B|A, C) = \mathbb{P}(B|A \cap C) = \mathbb{P}(B|C)$  pour  $\mathbb{P}(A) > 0$

(lorsque  $C$  est connu, la connaissance de  $A$  n'altère pas celle de  $B$ )

# Variable aléatoire

Une **variable aléatoire** (v.a.)  $X$  est définie sur  $\Omega$ , en associant à chaque résultat de l'expérience aléatoire un nombre réel  $x$  (la réalisation de  $X$ )

L'événement  $X = x$  prend en compte tous les résultats pour lesquels la variable  $X$  prend la valeur  $x$

Une v.a.  $X$  est dite **discrète** si l'ensemble des réalisations possibles  $x_1, x_2, \dots, x_n$  pour cette variable est fini ou dénombrable

Une v.a.  $X$  est dite **continue** si son domaine de variation est l'ensemble  $\mathbb{R}$  ou un intervalle de  $\mathbb{R}$



# Loi de probabilité

**Cas discret** : A chacune des réalisations  $x_i$  de la v.a.  $X$  est associée une probabilité  $\mathbb{P}(X = x_i) = p_i$  avec  $0 \leq p_i \leq 1, \forall i$

L'ensemble des couples  $(x_i, p_i)$  forme une loi de probabilité si la somme de toutes ses probabilités est égale à 1,  $\sum_{i=1}^n p_i = 1$

**Cas continu** : La loi de probabilité est décrite par la **fonction de densité**  $f(x) = \lim_{\Delta \rightarrow 0} \frac{1}{\Delta} \mathbb{P}[x \leq X < x + \Delta]$

- ▶  $f(x) \geq 0 \quad \forall x$
- ▶ Surface totale sous la courbe

$$\int_{-\infty}^{+\infty} f(x) dx = 1$$

# Fonction de répartition

**Définition générale :**  $F(x) = F_X(x) = \mathbb{P}(X \leq x)$

–Cas discret :  $F(x) = \sum_{x_i \leq x} \mathbb{P}(X = x_i)$

–Cas continu :  $F(x) = \int_{-\infty}^x f(u) du$

**Propriétés générales :**

- ▶ Fonction monotone croissante entre 0 et 1,  $0 \leq F(x) \leq 1$
- ▶ Si  $a \leq b$ , alors  $F(a) \leq F(b)$
- ▶  $\mathbb{P}(a < X \leq b) = F(b) - F(a)$
- ▶  $\lim_{x \rightarrow -\infty} F(x) = 0$  et  $\lim_{x \rightarrow +\infty} F(x) = 1$

# Espérance

–Cas discret :  $\mathbb{E}(X) = \sum_{i=1}^n x_i \mathbb{P}(X = x_i) = \sum_{i=1}^n x_i p_i$

–Cas continu :  $\mathbb{E}(X) = \int_{-\infty}^{+\infty} x f(x) dx$

**Propriétés générales** : soient  $X$  et  $Y$  deux v.a.

- ▶  $\mathbb{E}(a) = a \quad \forall a \in \mathbb{R}$
- ▶  $\mathbb{E}(aX + b) = a\mathbb{E}(X) + b \quad \forall (a, b) \in \mathbb{R}^2$
- ▶  $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$
- ▶  $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$  si  $X$  et  $Y$  indépendants
- ▶  $\mathbb{E}[h(X)] = \sum_i h(x_i) \mathbb{P}(X = x_i)$  si  $X$  discret,  
 $\mathbb{E}[h(X)] = \int_{-\infty}^{+\infty} h(x) f(x) dx$  si  $X$  continu

# Variance

$$\text{Var}(X) = \sigma^2(X) = \mathbb{E} \{ [X - \mathbb{E}(X)]^2 \} = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$$

–**Cas discret** :  $\text{Var}(X) = \sum_i [x_i - \mathbb{E}(X)]^2 \mathbb{P}(X = x_i)$

–**Cas continu** :  $\text{Var}(X) = \int_{-\infty}^{+\infty} [x - \mathbb{E}(X)]^2 f(x) dx$

**Propriétés générales** : soient  $X$  une v.a. et  $a \in \mathbb{R}$

- ▶  $\text{Var}(X) \geq 0$
- ▶  $\text{Var}(a) = 0$ ,  $\text{Var}(X + a) = \text{Var}(X)$
- ▶  $\text{Var}(aX) = a^2 \text{Var}(X)$
- ▶ si  $X$  et  $Y$  indépendants,  $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$   
Attention, la réciproque est fausse !
- ▶  $\text{Var}[h(X)] = \mathbb{E}[h^2(X)] - \mathbb{E}^2[h(X)]$

**Ecart-type** :  $\sigma_X(X) = \sigma(X) = \sqrt{\text{Var}(X)}$

# Inégalités intéressantes

**Inégalité de Markov** : si  $\forall x < 0, f(x) = 0$  ou  $p(x) = 0$  (v.a. ne prenant que des valeurs positives), alors

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}(X)}{a} \quad \forall a > 0$$

Preuve :

$$\mathbb{E}(X) = \int_0^{+\infty} x f(x) dx \geq \int_a^{+\infty} x f(x) dx \geq \int_a^{+\infty} a f(x) dx = a \mathbb{P}(X \geq a)$$

**Inégalité de Chebyshev** : pour une v.a.  $X$  quelconque

$$\mathbb{P}(|X - \mu| \geq a) \leq \frac{\text{Var}(X)}{a^2} \quad \forall a > 0$$

# Moments d'une variable aléatoire

Moments d'ordre  $k$  :  $\mathbb{E}(X^k) = \sum_{i=1}^n x_i^k p(x_i)$  (cas discret) ou

$$\int_{-\infty}^{+\infty} x^k f(x) dx \quad (\text{cas continu})$$

Moments centrés d'ordre  $k$  :  $\mathbb{E}[(X - \mu)^k] = \sum_{i=1}^n (x_i - \mu)^k p(x_i)$  (cas discret) ou

$$\int_{-\infty}^{+\infty} (x - \mu)^k f(x) dx \quad (\text{cas continu})$$

Coefficient d'asymétrie (*skewness*)  $\gamma = \mathbb{E}[(X - \mu)^3]/\sigma^3$

Coefficient d'aplatissement (*kurtosis*)  $\kappa = \mathbb{E}[(X - \mu)^4]/\sigma^4$

# Fonction génératrice de moments

$$G(t) = \mathbb{E} [e^{tX}] = \begin{cases} \sum_{i=1}^n e^{tx_i} p(x_i) & (\text{cas discret}) \\ \int_{-\infty}^{+\infty} e^{tx} f(x) dx & (\text{cas continu}) \end{cases}$$

$$\frac{d^k G(t)}{dt^k} = \begin{cases} \sum_{i=1}^n x_i^k e^{tx_i} p(x_i) & (\text{cas discret}) \\ \int_{-\infty}^{+\infty} x^k e^{tx} f(x) dx & (\text{cas continu}) \end{cases}$$

$$\frac{d^k G(t)}{dt^k} \Big|_{t=0} = \mathbb{E}(X^k)$$

**Exemples :**  $G(t) = \frac{e^{tb} - e^{ta}}{t(b-a)}$  pour  $X \sim \mathcal{U}(a, b)$ ,  $G(t) = \frac{\theta}{\theta - t}$  pour  $X \sim \mathcal{E}(\theta)$  et  $t < \theta$

# Fonction caractéristique

Transformée de Fourier de la fonction de densité  $f(x)$

$$\Psi(t) = \mathbb{E} [e^{itX}] = \begin{cases} \sum_{i=1}^n e^{itx_i} p(x_i) & \text{cas discret} \\ \int_{-\infty}^{+\infty} e^{itx} f(x) dx & \text{cas continu} \end{cases}$$

où  $i = \sqrt{-1}$  est le nombre imaginaire

Dans le cas continu  $f(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-itx} \Psi(t) dt$

## Propriétés

- ▶  $\Psi(t) = G(it)$
- ▶ si  $Y = aX + b$ ,  $\Psi_Y(t) = e^{ibt} \Psi_X(at)$
- ▶ si  $Y = h(X)$ ,  $\Psi_Y(t) = \int_{-\infty}^{+\infty} e^{ith(x)} f_X(x) dx = \int_{-\infty}^{+\infty} e^{ity} f_Y(y) dy$



# Processus temporels et fonction de survie

Les valeurs de la v.a. correspondent à des temps

**Fonction de survie** (ou fonction de fiabilité)

$$S(x) = \mathbb{P}(X > x) = 1 - F(x) \text{ avec } x > 0$$

**Fonction de répartition conditionnelle**

$$H(x, t) = \mathbb{P}(X \leq x + t | X > x) = \frac{F(x + t) - F(x)}{1 - F(x)} \text{ avec } t > 0$$

probabilité d'observer un individu présenter l'événement dans l'intervalle de temps  $]x, x + t]$  après l'instant  $x$  sachant qu'il était toujours en vie à l'instant  $x$

$$h(x) = \lim_{\Delta x \rightarrow 0} \frac{H(x, \Delta x)}{\Delta x} = \frac{f(x)}{1 - F(x)}$$

**Processus sans mémoire**  $\mathbb{P}(X \leq x + t | X > x) = \mathbb{P}(X \leq t)$  avec  $t > 0$   
 $\Rightarrow h(x)$  constant

Seules 2 lois vérifient cette propriété : géométrique (cas discret) et exponentielle (cas continu)

# Loi conjointe

Loi du couple  $(X, Y)$  pour  $X$  et  $Y$  deux v.a.

–**Cas discret** :

$$\begin{aligned}\mathbb{P}(X = x \cap Y = y) &= \mathbb{P}(Y = y)\mathbb{P}(X = x|Y = y) \\ &= \mathbb{P}(X = x)\mathbb{P}(Y = y|X = x)\end{aligned}$$

Si  $X$  et  $Y$  indépendants,  $\mathbb{P}(X = x \cap Y = y) = \mathbb{P}(X = x)\mathbb{P}(Y = y)$

–**Cas continu** :

$$\begin{aligned}\mathbb{P}(x_1 < X \leq x_2 \cap y_1 < Y \leq y_2) &= \int_{x_1}^{x_2} \int_{y_1}^{y_2} f(x, y) dx dy \\ &= \int_{y_1}^{y_2} \int_{x_1}^{x_2} f(x, y) dy dx\end{aligned}$$

Si  $X$  et  $Y$  indépendants,  $f(x, y) = f_X(x)f_Y(y)$

# Lois marginales

$$\text{--Cas discret} \quad \begin{cases} \mathbb{P}(X = x) = \sum_y \mathbb{P}(X = x \cap Y = y) \\ \mathbb{P}(Y = y) = \sum_x \mathbb{P}(X = x \cap Y = y) \end{cases}$$

$$\text{--Cas continu} \quad \begin{cases} f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy \\ f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx \end{cases}$$

$$(X, Y) \sim \mathcal{N}(\mu_X, \mu_Y, \sigma_X^2, \sigma_Y^2, \rho) \quad \Rightarrow \quad \begin{cases} X \sim \mathcal{N}(\mu_X, \sigma_X^2) \\ Y \sim \mathcal{N}(\mu_Y, \sigma_Y^2) \end{cases}$$

la réciproque n'est pas vraie

# Loi conditionnelle

Loi conditionnelle de  $Y|X$

– **Cas discret** :  $\mathbb{P}(Y = y|X = x) = \frac{\mathbb{P}(X = x \cap Y = y)}{\mathbb{P}(X = x)}$  si  $\mathbb{P}(X = x) \neq 0$

– **Cas continu** :  $f_{Y|X=x}(y) = \frac{f(x, y)}{f_X(x)}$  si  $f_X(x) \neq 0$

Propriétés générales :

- ▶  $\mathbb{E}(Y) = \mathbb{E}[\mathbb{E}(Y|X)]$ ,  $\mathbb{E}(Y|W) = \mathbb{E}[\mathbb{E}(Y|X, W)|W]$
- ▶  $\text{Var}(Y) = \mathbb{E}[\text{Var}(Y|X)] + \text{Var}[\mathbb{E}(Y|X)]$

# Covariance

**Définition générale** : soient  $X, Y$  deux v.a.

$$\text{Cov}(X, Y) = \mathbb{E} [\{X - \mathbb{E}(X)\}\{Y - \mathbb{E}(Y)\}] = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

## Propriétés

- ▶  $X$  et  $Y$  indépendants  $\Rightarrow \text{Cov}(X, Y) = 0$   
 $\Leftrightarrow \mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$
- ▶  $\text{Cov}(X, X) = \text{Var}(X)$
- ▶  $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$
- ▶  $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
- ▶  $\text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$
- ▶ Invariance par changement d'origine  
 $\text{Cov}(X + a, Y + b) = \text{Cov}(X, Y)$
- ▶  $\text{Cov}(aX, bY) = ab\text{Cov}(X, Y)$

# Coefficient de corrélation linéaire

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$$

## Propriétés

- ▶  $-1 \leq \rho(X, Y) \leq 1$ , les bornes sont atteintes ssi  $Y = a + bX$
- ▶  $\rho(X, X) = 1$
- ▶ si  $X$  et  $Y$  sont indépendants, alors  $\rho(X, Y) = 0$   
la réciproque est toujours vraie uniquement dans le cas où  $X$  et  $Y$  suivent une loi normale
- ▶  $\rho(\lambda X + a, \mu Y + b) = \frac{\lambda\mu}{|\lambda\mu|} \rho(X, Y)$

# Transformation d'une variable aléatoire

$$Y = h(X)$$

## Loi de probabilité

- ▶ Si  $h$  est bijective, c'est-à-dire  $h'(x) \neq 0$  alors  
 $f_Y(y) = f_X[u(y)]|u'(y)|$  où  $u = h^{-1}$  fonction réciproque de  $h$
- ▶ Si  $h$  n'est pas bijective, il faut raisonner à partir de la fonction de répartition

**$\Delta$ -méthode** : on note  $\mathbb{E}(X) = \mu$

- ▶ Espérance  $\mathbb{E}(Y) \approx h(\mu)$ ,  $\mathbb{E}[h(X)] \approx h[\mathbb{E}(X)]$
- ▶ Variance  $\text{Var}(Y) \approx [h'(\mu)]^2 \text{Var}(X)$ ,  
 $\text{Var}[h(X)] \approx (h'[\mathbb{E}(X)])^2 \text{Var}(X)$

# Matrice de variance-covariance (1)

Soit un vecteur de v.a.  $\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix}$

**Définition :**  $\Sigma_{(p \times p)} = \mathbb{E} [(\mathbf{X} - \mathbb{E}[\mathbf{X}]) \cdot (\mathbf{X} - \mathbb{E}[\mathbf{X}])^\top] \quad \Leftrightarrow$

$\forall (i, j) \in \{1, \dots, p\} \times \{1, \dots, p\} \quad \Sigma_{ij} = \mathbb{E}[(X_i - \mu_i)(X_j - \mu_j)] \quad \text{où}$   
 $\mu_i = \mathbb{E}(X_i)$  est l'espérance de la v.a.  $X_i$  (scalaire)

**Note :** matrice de **variance** comme généralisation de la variance  $\sigma^2 = \mathbb{E}[(X - \mu)^2]$  pour un vecteur de dimension 1 (William Feller), ou matrice de **covariance** entre les composantes scalaires de  $\mathbf{X}$  (variances en termes diagonaux)

Source : [http://en.wikipedia.org/wiki/Covariance\\_matrix](http://en.wikipedia.org/wiki/Covariance_matrix)



## Matrice de variance-covariance (2)

$\Sigma^{-1}$  inverse de la matrice de variance-covariance est aussi appelée *concentration matrix* ou *precision matrix*

### Propriétés

- ▶  $\Sigma = \mathbb{E}[\mathbf{X}\mathbf{X}^\top] - \mu\mu^\top$  où  $\mu = \mathbb{E}(\mathbf{X})$  vecteur de dimension  $p$
- ▶  $\Sigma$  est positive semi-définie (*positive semi-definite*)
- ▶  $\text{Var}(\mathbf{A}\mathbf{X} + \mathbf{a}) = \mathbf{A}\text{Var}(\mathbf{X})\mathbf{A}^\top$  pour  $\mathbf{a}$  vecteur  $q \times 1$  et  $\mathbf{A}$  matrice  $q \times p$

## Covariance entre 2 v.a. de dimension multiple (1)

Soit  $X \in \mathbb{R}^p, Y \in \mathbb{R}^q$

$$\begin{aligned}\text{Cov}(X, Y) &= \mathbb{E} \left[ (X - \mathbb{E}[X]) \cdot (Y - \mathbb{E}[Y])^\top \right] \\ &\quad (p \times q) \\ &= \mathbb{E}(XY^\top) - \mathbb{E}(X)\mathbb{E}(Y)^\top \\ &\quad (p \times 1)(1 \times q) \quad (p \times 1) \quad (1 \times q)\end{aligned}$$

**Note :** on parle aussi de *cross-covariance* pour distinguer de la matrice de variance-covariance pour un vecteur de v.a.

## Covariance entre 2 v.a. de dimension multiple (2)

### Propriétés

- ▶  $\text{Cov}(\underset{(p \times q)}{\mathbf{X}}, \underset{(q \times p)}{\mathbf{Y}}) \neq \text{Cov}(\mathbf{Y}, \mathbf{X})$  mais  $\text{Cov}(\mathbf{X}, \mathbf{Y}) = \text{Cov}(\mathbf{Y}, \mathbf{X})^\top$
- ▶  $\text{Cov}(\mathbf{X}_1 + \mathbf{X}_2, \mathbf{Y}) = \text{Cov}(\mathbf{X}_1, \mathbf{Y}) + \text{Cov}(\mathbf{X}_2, \mathbf{Y})$
- ▶ Si  $p = q$ , alors  
 $\text{Var}(\mathbf{X} + \mathbf{Y}) = \text{Var}(\mathbf{X}) + \text{Cov}(\mathbf{X}, \mathbf{Y}) + \text{Cov}(\mathbf{Y}, \mathbf{X}) + \text{Var}(\mathbf{Y})$
- ▶  $\text{Cov}(\mathbf{A}\mathbf{X}, \mathbf{B}^\top \mathbf{Y}) = \mathbf{A} \text{Cov}(\mathbf{X}, \mathbf{Y}) \mathbf{B}$
- ▶ Si  $\mathbf{X}$  et  $\mathbf{Y}$  sont indépendants, alors  $\text{Cov}(\mathbf{X}, \mathbf{Y}) = 0$

pour  $\mathbf{X}$ ,  $\mathbf{X}_1$  et  $\mathbf{X}_2$  vecteurs aléatoires  $p \times 1$ ,  $\mathbf{Y}$  vecteur aléatoire  $q \times 1$ ,  
 $\mathbf{a}$  vecteur (non aléatoire)  $q \times 1$ ,  $\mathbf{A}$  et  $\mathbf{B}$  matrices  $q \times p$

# Loi de Bernoulli

Expérience aléatoire avec 2 résultats possibles :  $E$  et  $\bar{E}$ , avec  $\mathbb{P}(E) = p$  et  $\mathbb{P}(\bar{E}) = 1 - p = q$

$$\text{v.a. } X = \begin{cases} 1 & \text{si } E \\ 0 & \text{si } \bar{E} \end{cases} \quad \text{notée } X \sim \mathcal{B}(p), \mathbb{P}(X = 1) = p$$

$$\mathbb{E}(X) = p, \quad \text{Var}(X) = pq$$

**Exemple** : Lancer de pièce

Ensemble des événements = {Pile, Face}

Pour une pièce non truquée,  $p = 0.5$

donc  $\mathbb{E}(X) = 0.5$  et  $\text{Var}(X) = 0.25$

# Loi binomiale

Somme de  $n$  v.a. de Bernoulli indépendantes (tirage avec remise), de même paramètre  $p$

v.a.  $Y = \sum_{i=1}^n X_i$  notée  $Y \sim \mathcal{B}(n, p)$

$Y$  a  $(n + 1)$  valeurs possibles : pour  $k = 0, 1, \dots, n$

$$\mathbb{P}(Y = k) = \binom{n}{k} p^k q^{n-k} \quad \text{où} \quad \binom{n}{k} \equiv C_n^k = \frac{n!}{k!(n-k)!}$$

$$\mathbb{E}(Y) = np, \quad \text{Var}(Y) = npq$$

**Note** : quand  $n$  devient grand, le calcul des factorielles devient laborieux  $\rightarrow$  voir approximations plus loin

# Loi hypergéométrique

Répétition d'une épreuve de Bernoulli sans remise  $\rightarrow$  Somme de  $n$  v.a. de Bernoulli non indépendantes parmi  $N$

$Y$  a pour valeurs possibles :  $\max(0, n + k - N), \dots, \min(n, k)$

$$\mathbb{P}(Y = x) = \frac{C_k^x C_{N-k}^{n-x}}{C_N^n}$$

# Loi géométrique

Nombre de fois qu'il faut répéter une épreuve de Bernoulli pour obtenir une première réussite

$Y$  a pour valeurs possibles  $\{1, 2, \dots\}$

$$\mathbb{P}(Y = k) = p(1 - p)^{k-1}$$

$$F(y) = 1 - (1 - p)^y$$

# Loi de Pascal ou loi binomiale négative

Nombre de répétitions d'épreuves de Bernoulli indépendantes  
nécessaire pour obtenir  $k$  réussites

Somme de  $k$  variables géométriques indépendantes

$$\mathbb{P}(Y = x) = C_{x-1}^{k-1} p^k (1-p)^{x-k}, \quad x = k, k+1, \dots$$



# Loi de Poisson

La v.a.  $X$  suit une loi de Poisson de paramètre  $\lambda$ ,  $\lambda > 0$  (réel), si  $X$  est un comptage d'événements avec

$$\mathbb{P}(X = k) = \frac{e^{-\lambda} \lambda^k}{k!} \quad \forall k \geq 0$$

$$X \sim \mathcal{P}(\lambda)$$

$$\mathbb{E}(X) = \lambda, \quad \text{Var}(X) = \lambda$$

**Note :**  $\mathbb{E}(X) = \text{Var}(X)$  est une condition nécessaire mais pas suffisante de la loi de Poisson, elle constitue une contrainte forte pour la modélisation


**Approximation de la loi binomiale par la loi de Poisson**

Conditions :  $n \rightarrow \infty$  et  $p \rightarrow 0$ , alors  $\mathcal{B}(n, p) \rightarrow \mathcal{P}(\lambda)$  avec  $np = \lambda$

# Loi uniforme

Une variable aléatoire continue  $X$  est dite de loi (ou distribution)

uniforme sur  $[a, b]$  si  $f(x) = \begin{cases} \frac{1}{b-a} & \text{si } a \leq x \leq b \\ 0 & \text{sinon} \end{cases}$



On note  $X \sim \mathcal{U}(a, b)$ ; on a  $\mathbb{E}(X) = \frac{a+b}{2}$ ,  $\text{Var}(X) = \frac{(b-a)^2}{12}$

# Loi exponentielle

Une v.a.  $X$  est dite de loi exponentielle de paramètre  $\theta > 0$  si

$$f(x) = \begin{cases} \theta e^{-\theta x} & \text{si } x \geq 0 \\ 0 & \text{sinon} \end{cases}$$

$$X \sim \mathcal{E}(\theta)$$

$$\mathbb{E}(X) = \frac{1}{\theta}, \quad \text{Var}(X) = \frac{1}{\theta^2}$$

**Exemples** : temps d'attente, analyse de survie

# Loi normale (Laplace-Gauss)

Si  $Y \sim \mathcal{N}(\mu, \sigma^2)$ , sa densité est  $f(y) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[ -\frac{1}{2} \left( \frac{y - \mu}{\sigma} \right)^2 \right]$

$Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1)$  loi normale centrée réduite  $\rightarrow$  tables

**Théorème central limite** : La loi de probabilité de la somme de  $n$  variables indépendantes de même loi (continue quelconque) tend vers une loi normale quand  $n$  est grand

# Loi Beta

Une v.a.  $X$  est dite de loi beta de paramètres  $a > 0$  et  $b > 0$  si

$$f(x) = \begin{cases} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1} & \text{si } x \in [0, 1] \\ 0 & \text{sinon} \end{cases}$$

$$X \sim \text{Beta}(a, b)$$

$$\mathbb{E}(X) = \frac{a}{a+b}, \quad \text{Var}(X) = \frac{ab}{(a+b)^2(a+b+1)}$$

# Loi du Chi-deux

Somme de  $\nu$  v.a. de loi normale centrée réduite  $\mathcal{N}(0, 1)$  indépendantes

v.a.  $Y = \sum_{i=1}^{\nu} X_i^2$  notée  $Y \sim \chi_{\nu}^2$  avec  $\nu \in \mathbb{N}$

$$f(y) = \frac{e^{-y/2} y^{\nu/2-1}}{2^{\nu/2} \Gamma(\nu/2)} \quad \text{pour } y \geq 0$$

$$\mathbb{E}(Y) = \nu, \quad \text{Var}(Y) = 2\nu$$

**En pratique :** table

# Loi de Student

Si  $Z \sim \mathcal{N}(0, 1)$  et  $U \sim \chi_\nu^2$  sont indépendantes alors la v.a.  $Y = Z/\sqrt{\frac{U}{\nu}}$  notée  $Y \sim t_\nu$  suit une loi de student à  $\nu$  degrés de liberté.

$$f(y) = \frac{1}{\sqrt{\nu\pi}} \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{y^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

$$\mathbb{E}(Y) = 0 \quad \text{si } \nu > 1, \quad \text{Var}(Y) = \frac{\nu}{\nu-2} \quad \text{si } \nu > 2$$

# Loi de Fisher-Snedecor



# Générateur aléatoire uniforme

Formule de Lehmer :  $x_{i+1} = ax_i \bmod b \quad i = 0, 1, \dots, n-1$  où  $b \in \mathbb{N}$  et  $a \in \{1, 2, \dots, b-1\}$

Permet de générer une séquence pseudo-aléatoire de nombres entiers allant de 0 à  $b-1$  à partir du **germe** (*seed* = valeur de départ)  
 $x_0 \in \{1, \dots, b-1\}$

Avec un bon choix des paramètres  $a$  et  $b$ , les valeurs  $x_1, x_2, \dots$  peuvent raisonnablement être considérées comme des réalisations de v.a.  $X_1, X_2, \dots$  indépendantes et identiquement distribuées, de fonction de probabilité  $p_X(x) = \frac{1}{b} \quad x = 0, 1, \dots, b-1$

$$a = 2^7 - 1, \quad b = 2^{31} - 1$$

Pour obtenir une séquence de nombres pseudo-aléatoires uniformément distribués entre 0 et 1, prendre  $y_i = \frac{x_i}{b} \quad i = 1, \dots, n$

# Génération d'une variable aléatoire par inversion

$$\begin{cases} X \sim \mathcal{U}(0, 1) \\ Y = h^{-1}(X) \\ h^{-1} \nearrow \end{cases} \quad \Rightarrow \quad F_Y(y) = \begin{cases} 0 & y < h^{-1}(0) \\ h(y) & y \in [h^{-1}(0), h^{-1}(1)] \\ 1 & y > h^{-1}(1) \end{cases}$$

**Exemple**— Pour générer  $y_1, y_2, \dots$ , réalisations de  $Y \sim \mathcal{E}(\lambda)$  à partir de  $x_1, x_2, \dots$ , réalisations de  $X \sim \mathcal{U}(0, 1)$

$$F_Y(y) = h(y) = 1 - e^{-\lambda y} \quad \Rightarrow \quad F_Y^{-1}(x) = h^{-1}(x) = -\frac{1}{\lambda} \ln(1 - x)$$

d'où la transformation adéquate  $y_i = -\frac{1}{\lambda} \ln(1 - x_i)$

## Deuxième partie II

### Statistique inférentielle



# Introduction à la statistique

Soit un échantillon de  $n$  individus indépendants pour lesquels on observe les réalisations  $x_1, x_2, \dots, x_n$  de la v.a.  $X$

Définition : on appelle **statistique** toute fonction exprimée en terme des variables composant l'échantillon  $T = h(X_1, \dots, X_n)$

Cette statistique est fonction de l'échantillon, sa valeur réalisée sur l'échantillon  $t = h(x_1, \dots, x_n)$

On note  $x_{(1)}, \dots, x_{(n)}$  les valeurs ordonnées par ordre croissant des réalisations de  $X$  sur l'échantillon

# Paramètres/statistiques de position : “où est la mesure ?”

**Minimum**  $L = \min(X_1, \dots, X_n) = X_{(1)}$

**Maximum**  $U = \max(X_1, \dots, X_n) = X_{(n)}$

**Mode**  $M_o$  : valeur (ou centre de la classe des valeurs) la plus fréquente, c'est-à-dire  $x_m$  telle que  $\forall x, p(x_m) \geq p(x)$  ou  $f(x_m) \geq f(x)$

**Médiane**  $M_e$  : valeur qui partage les observations ordonnées en 2 groupes d'effectifs égaux, c'est-à-dire il y a autant d'observations strictement inférieures à  $M_e$  que d'observations strictement supérieures à  $M_e$  :  $\mathbb{P}(X \leq \tilde{m}) = F(\tilde{m}) = 1/2$

$$\tilde{X} = \begin{cases} X_{(\frac{n+1}{2})} & n \text{ impair} \\ \frac{1}{2} \left[ X_{(\frac{n}{2})} + X_{(\frac{n}{2}+1)} \right] & n \text{ pair} \end{cases}$$

**Quantile** (ou fractile) :  $x_{100p}$  telle que  $\mathbb{P}(X \leq x_{100p}) = p$ ,  $p \in [0, 1]$

Exemples : médiane  $x_{50}$  ; quartiles  $x_{25}, x_{50}, x_{75}$  ; déciles

$x_{10}, x_{20}, \dots, x_{90}$  ; centiles  $x_1, x_2, \dots, x_{99}$

**Moyenne** arithmétique  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

# Paramètres/statistiques d'échelle (dispersion/précision de la mesure)

**Etendue** (*range*)  $R = U - L = X_{(n)} - X_{(1)}$

**Intervalle interquartiles**  $x_{75} - x_{25}$

**Variance** 
$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left( \sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) = \frac{1}{n-1} \left[ \sum_{i=1}^n x_i^2 - \frac{1}{n} \left( \sum_{i=1}^n x_i \right)^2 \right]$$

**Ecart-type**  $S = \sqrt{S^2} \geq 0$  s'exprime dans la même unité que les valeurs observées

**Coefficient de variation**  $CV = \frac{s}{\bar{x}}$  sans unité, souvent exprimé en %

# Estimateurs ponctuels des moments

$$\widehat{\mathbb{E}}[X] = \hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\widehat{\mathbb{E}}[X^k] = \frac{1}{n} \sum_{i=1}^n X_i^k$$

$$\widehat{\mathbb{E}}[(X - \mu)^k] = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

$$\hat{\sigma}^2 = S^2 = \frac{n}{n-1} \widehat{\mathbb{E}}[(X - \mu)^k]$$

$$\hat{\sigma} = S = \sqrt{S^2}$$



## Estimateurs ponctuels de "probabilités"

$$\hat{\mathbb{P}}(a < X \leq b) = \frac{\#\{a < X_i \leq b\}}{n}$$

$$\hat{F}(x) = \frac{\#\{X_i \leq x\}}{n}$$

$$\hat{\mathbb{P}}(X = x) = \frac{\#\{X_i = x\}}{n}$$

$$\hat{f}(x) = \frac{\#\{x - \Delta x < X_i \leq x + \Delta x\}}{2n\Delta x} \quad \Delta x > 0 \text{ petit}$$

# Représentations graphiques pour une variable aléatoire

**Variable discrète** : diagramme en bâtons, *pie* (camembert)...

**Variable continue** : histogramme des fréquences  $\hat{\mathbb{P}}(a_k < X \leq a_{k+1})$ ,  
*box plot* (boîte à moustaches)...

# Statistiques d'ordre

Si les  $X_i$  sont i.i.d. de loi de probabilité continue  $f(x)$  alors

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1-F(x)]^{n-k} f(x)$$

En particulier, pour  $\min(X_1, \dots, X_n) = X_{(1)}$  et  
 $\max(X_1, \dots, X_n) = X_{(n)}$

$$f_{(1)}(x) = n [1-F(x)]^{n-1} f(x), \quad f_{(n)}(x) = n [F(x)]^{n-1} f(x)$$

# Qualités d'un estimateur

$\theta$  valeur théorique du paramètre,  $\hat{\Theta}$  estimateur pour ce paramètre

**Biais**  $b(\hat{\Theta}) = \mathbb{E}[\hat{\Theta}] - \theta$

- ▶ Estimateur sans biais (non biaisé)  $b(\hat{\Theta}) = 0$
- ▶ Estimateur asymptotiquement sans biais  $\lim_{n \rightarrow \infty} b(\hat{\Theta}) = 0$

# Qualités d'un estimateur

$\theta$  valeur théorique du paramètre,  $\hat{\Theta}$  estimateur pour ce paramètre

**Biais**  $b(\hat{\Theta}) = \mathbb{E}[\hat{\Theta}] - \theta$

- ▶ Estimateur sans biais (non biaisé)  $b(\hat{\Theta}) = 0$
- ▶ Estimateur asymptotiquement sans biais  $\lim_{n \rightarrow \infty} b(\hat{\Theta}) = 0$

$\bar{X}$  et  $S^2$  sont des estimateurs sans biais de  $\mu$  et  $\sigma^2$ , respectivement  
 $\hat{\mathbb{E}}[(X - \mu)^k]$  est un estimateur biaisé mais asymptotiquement sans biais de  $\sigma^2$

# Efficacité et consistance

**Efficacité** : Erreur quadratique moyenne

$EQM(\hat{\Theta}) = \mathbb{E}[(\hat{\Theta} - \theta)^2] = \text{Var}(\hat{\Theta}) + b^2(\hat{\Theta})$  finie et minimale

# Efficacité et consistance

**Efficacité** : Erreur quadratique moyenne

$EQM(\hat{\Theta}) = \mathbb{E}[(\hat{\Theta} - \theta)^2] = \text{Var}(\hat{\Theta}) + b^2(\hat{\Theta})$  finie et minimale

**Consistance** :  $\lim_{n \rightarrow \infty} \mathbb{P}[|\hat{\Theta} - \theta| > \varepsilon] = 0$  convergence en probabilité

# Méthode des moments

En supposant que les moments théoriques  $\mathbb{E}[X], \mathbb{E}[X^2], \dots, \mathbb{E}[X^p]$  peuvent s'écrire comme fonctions des paramètres inconnus

$\theta_1, \theta_2, \dots, \theta_p$

$$\begin{cases} \mathbb{E}[X] &= h_1(\theta_1, \dots, \theta_p) = h_1(\theta) \\ \mathbb{E}[X^2] &= h_2(\theta_1, \dots, \theta_p) = h_2(\theta) \\ &\vdots \\ \mathbb{E}[X^p] &= h_p(\theta_1, \dots, \theta_p) = h_p(\theta) \end{cases}$$



# Méthode des moments

En supposant que les moments théoriques  $\mathbb{E}[X], \mathbb{E}[X^2], \dots, \mathbb{E}[X^p]$  peuvent s'écrire comme fonctions des paramètres inconnus

$\theta_1, \theta_2, \dots, \theta_p$

$$\begin{cases} \mathbb{E}[X] &= h_1(\theta_1, \dots, \theta_p) = h_1(\theta) \\ \mathbb{E}[X^2] &= h_2(\theta_1, \dots, \theta_p) = h_2(\theta) \\ &\vdots \\ \mathbb{E}[X^p] &= h_p(\theta_1, \dots, \theta_p) = h_p(\theta) \end{cases}$$

Si ce système d'équations peut être résolu par rapport à  $\theta_1, \dots, \theta_p$ , on obtient

$$\begin{cases} \theta_1 = g_1(\mathbb{E}[X], \mathbb{E}[X^2], \dots, \mathbb{E}[X^p]) \\ \vdots \\ \theta_p = g_p(\mathbb{E}[X], \mathbb{E}[X^2], \dots, \mathbb{E}[X^p]) \end{cases}$$

# Méthode des moments

On remplace les moments théoriques par leurs estimateurs

$$\widehat{\mathbb{E}}[X^k] = \frac{1}{n} \sum_{i=1}^n X_i^k \quad \forall k = 1, \dots, p$$

$$\begin{cases} \widehat{\Theta}_1 = g_1(\widehat{\mathbb{E}}[X], \widehat{\mathbb{E}}[X^2], \dots, \widehat{\mathbb{E}}[X^p]) \\ \vdots \\ \widehat{\Theta}_p = g_p(\widehat{\mathbb{E}}[X], \widehat{\mathbb{E}}[X^2], \dots, \widehat{\mathbb{E}}[X^p]) \end{cases}$$

**Note** : on peut aussi utiliser les moments centrés  $\mathbb{E}[(X - \mu)^k]$

# Estimateurs pour les lois usuelles par la méthode des moments

$$X \sim \mathcal{B}(n, p) \quad \longrightarrow \quad \hat{p} = \frac{1}{n} \bar{X}$$

$$X \sim \mathcal{G}(p) \quad \longrightarrow \quad \hat{p} = \frac{1}{\bar{X}}$$

$$X \sim \mathcal{P}(\mu) \quad \longrightarrow \quad \hat{\mu} = \bar{X}$$

Certains de ces estimateurs sont biaisés mais ils sont tous asymptotiquement sans biais

# Estimateurs pour les lois usuelles par la méthode des moments

$$X \sim \mathcal{U}(0, b) \quad \longrightarrow \quad \hat{b} = 2\bar{X}$$

$$X \sim \mathcal{U}(a, b) \quad \longrightarrow \quad \hat{a} = \bar{X} - \sqrt{3\frac{n-1}{n}S^2}, \hat{b} = \bar{X} + \sqrt{3\frac{n-1}{n}S^2}$$

$$X \sim \mathcal{E}(\lambda) \quad \longrightarrow \quad \hat{\lambda} = \frac{1}{\bar{X}}$$

$$X \sim \mathcal{N}(0, \sigma^2) \quad \longrightarrow \quad \hat{\sigma}^2 = \widehat{\mathbb{E}}[X^2]$$

$$X \sim \mathcal{N}(\mu, \sigma^2) \quad \longrightarrow \quad \hat{\mu} = \bar{X}, \hat{\sigma}^2 = \frac{n-1}{n}S^2$$

Certains de ces estimateurs sont biaisés mais ils sont tous asymptotiquement sans biais